

INSTITUTO TECNOLÓGICO DE BUENOS AIRES – ITBA
ESCUELA DE GESTIÓN Y NEGOCIOS



CREATIVE DIVERSITY Y AD PERFORMANCE EN TIKTOK

Análisis de Dimensiones Creativas y Click Through Rate

AUTOR: Jaureguiberry, Camilo (Leg. N° 105638)

TUTOR: Visco Comandini, Filippo

TESIS PRESENTADA PARA LA OBTENCIÓN DEL TÍTULO DE MAGÍSTER EN
MANAGEMENT & ANALYTICS

BUENOS AIRES
PRIMER SEMESTRE, 2026

Abstract

En el ecosistema actual de *performance marketing* la compra de medios se encuentra prácticamente automatizada por algoritmos de las redes sociales (Meta, Google, TikTok, entre otras). Lo que históricamente diferenciaba a los anunciantes más exitosos era su capacidad de construir audiencias precisas, segmentar con mayor granularidad que la competencia e identificar qué formatos y mensajes resonaban con cada segmento para explotarlos sistemáticamente. Hoy, esa ventaja ha sido absorbida por los propios algoritmos de las plataformas, que aprenden a optimizar la distribución con una velocidad y escala que ningún equipo humano puede igualar. El resultado es un desplazamiento de la ventaja competitiva del anunciante: desde el dominio de la segmentación y la compra de medios, hacia la pieza creativa en sí misma. En este nuevo paradigma, el *media buying* efectivo es también el que produce mejores anuncios: es el *creative insight* y la diversidad creativa los que determinan quién gana la pulseada de atención del usuario. Para los equipos de *media buying*, esto genera un desafío concreto: ante la proliferación de formatos, conceptos y estilos posibles, ¿qué atributos creativos deben priorizarse para maximizar el rendimiento publicitario? La literatura existente reconoce la relevancia de la diversidad creativa, pero carece de evidencia empírica sistemática sobre cuáles de sus dimensiones se asocian más fuertemente con métricas de performance en plataformas de video corto como TikTok.

El presente estudio aborda esta brecha proponiendo una metodología cuantitativa replicable para rankear las dimensiones del Creative Diversity Score (CDS) de Ready Set según su asociación con el *Click Through Rate* (CTR), y demostrando su aplicación sobre 578 “Top Ads” del primer trimestre de 2025 en TikTok. El CDS es un marco de diagnóstico que convierte la abstracción de “variedad creativa” en una métrica estructurada y comparable. De sus seis dimensiones, el estudio modela tres (*Creative Theme*, *Creative Concept* y *Talent Type*): las restantes no son analizables con este corpus porque el dataset es exclusivamente TikTok (sin varianza entre plataformas ni formatos) y porque el etiquetado de funnel stage requiere información del equipo de marca que no está disponible en los datos de Top Ads. Los resultados específicos son válidos para el período analizado. La contribución principal es el *pipeline* analítico, diseñado para repetirse con cualquier dataset actualizado. Se realizó un análisis univariado descriptivo, seguido de un modelo de Random Forest (RF) con valores SHAP para identificar qué dimensiones creativas tienen mayor importancia predictiva sobre el CTR, y un modelo de Mínimos Cuadrados Ordinarios (OLS) para cuantificar la dirección y magnitud de

la asociación de cada categoría. Cada modelo cumple un rol distinto: RF determina qué dimensiones importan. OLS explica cuánto y en qué sentido. Usados en conjunto, los dos modelos se validan mutuamente.

De manera consistente entre ambos métodos, los contenidos anclados a eventos o momentos específicos, las colaboraciones con creadores aspiracionales y las narrativas de vida cotidiana emergieron como los formatos con mayor asociación positiva al CTR. En el extremo opuesto, el contenido puramente humorístico o de entretenimiento, los formatos basados en memes y las piezas sin presencia humana mostraron asociaciones negativas consistentes. La correlación entre los coeficientes OLS ponderados por prevalencia y los valores SHAP resultó alta ($\rho = 0,74, p < 0,001$), lo que valida la consistencia interna del enfoque metodológico propuesto. El alcance del estudio es exploratorio y de asociación: no se establecen relaciones causales.

En un entorno MarTech/AdTech cada vez más automatizado, el valor de este trabajo reside en demostrar que es posible construir un proceso sistemático y replicable para identificar qué dimensiones de la diversidad creativa merecen atención en un contexto y período determinados. La Inteligencia Artificial escala el alcance, pero contar con una metodología que oriente la elección creativa es lo que le da a esa escala algo valioso que amplificar.

Palabras clave: Creative Diversity, TikTok, CTR, Ad Performance, Creative Diversity Score, Random Forest, OLS, Paid Social, MarTech.

Índice general

Abstract	1
Índice de Figuras	6
Índice de Tablas	7
1 Introducción	1
1.1 La batalla por la atención en el feed	2
1.2 Diversidad creativa como palanca de micro-segmentación	3
1.3 El aporte del marco ReadySet CDS	3
1.4 Pregunta de investigación y objetivos	4
1.4.1 Pregunta de investigación	4
1.4.2 Objetivo principal	4
1.4.3 Objetivos secundarios	5
1.4.4 Hipótesis	5
2 Revisión de la Literatura	6
2.1 Estrategia creativa y rendimiento en plataformas digitales	6
2.2 Métricas clave: CTR y CPA en campañas de respuesta directa	7
2.3 Fatiga creativa y necesidad de diversidad	8
2.4 Diversidad creativa y Creative Diversity Score (CDS)	9
2.4.1 Ejemplo de análisis usando el CDS	10
2.4.2 Hallazgos principales	10
2.5 Desafíos metodológicos: causalidad vs. asociación	11
2.5.1 Ejemplo de experimento para identificar la relación causal	12
2.6 Marco estadístico para el análisis de atributos creativos	12
2.6.1 Regresión OLS para variables de respuesta categórica: supuestos, limitaciones y justificación	12
2.6.2 Random Forest como complemento no paramétrico: importancia de variables e interpretabilidad	14
2.6.3 La complementariedad entre enfoques lineales y no lineales	16

3	Metodología	18
3.1	Recolección y anotación de datos	18
3.2	Feature Engineering	19
3.3	Enfoque analítico	20
3.3.1	Modelo de Mínimos Cuadrados Ordinarios (OLS)	21
3.3.2	Modelo Random Forest	22
3.3.3	Análisis de robustez	24
3.4	Limitaciones del estudio	25
4	Resultados	27
4.1	Análisis Exploratorio de los Datos	27
4.2	Análisis Univariado	27
4.2.1	Creative Theme	29
4.2.2	Creative Concept	29
4.2.3	Talent Type	29
4.3	Análisis Multivariado	29
4.3.1	Mínimos Cuadrados Ordinarios (OLS)	29
4.3.2	Random Forest y análisis SHAP	32
4.3.3	Convergencia entre modelos	34
5	Conclusión	37
5.1	Alineación con la teoría de Direct Response	37
5.2	Implicancias para equipos creativos y de medios	38
5.3	Análisis multivariado versus univariado	39
5.4	Limitaciones del estudio	40
5.5	Relación con el marco de Creative Diversity Score (CDS)	41
5.6	Líneas futuras de investigación	42
A	Anexos	47
A.1	Tabla de Acrónimos	47
A.2	Resultados Regresión Lineal	47

Índice de figuras

3.1	Distribución del CTR original (izquierda) y de $\log(\text{CTR})$ (derecha). La transformación logarítmica reduce la asimetría de 6,78 a 1,87 y elimina la cola derecha extrema, haciendo la distribución más apta para el modelo OLS. El pico visible en $\log(\text{CTR}) \approx -4,6$ corresponde al valor mínimo reportado de $\text{CTR} = 0,01$ (<i>floor effect</i>).	19
3.2	Gráficos de diagnóstico del modelo OLS. Superior derecha: Q-Q plot de residuos, con ajuste razonable a la línea teórica salvo en los extremos. Inferior izquierda: distribución de residuos aproximadamente simétrica. Ambos gráficos sugieren que la desviación de normalidad no compromete la inferencia.	22
3.3	R^2 out-of-sample por fold en la validación cruzada de 5 folds para OLS y Random Forest. Las líneas punteadas indican los promedios (OLS: 0,496, RF: 0,519). La variabilidad entre folds es mayor en el RF, reflejo de su mayor sensibilidad a la composición de la muestra de training. . .	23
4.1	CTR medio por categoría para las tres dimensiones creativas analizadas. Las barras representan el CTR promedio por grupo. El tamaño de muestra por categoría varía considerablemente.	28
4.2	Coeficientes OLS con intervalos de confianza al 95 % para las variables creativas. Los puntos a la derecha de la línea cero indican asociación positiva con $\log(\text{CTR})$. Los de la izquierda indican asociación negativa.	31
4.3	SHAP <i>beeswarm plot</i> : las 20 variables con mayor importancia promedio $ \text{SHAP} $. Cada punto representa una observación. El color indica el valor de la variable (rojo = alto, azul = bajo). La posición horizontal indica el impacto en la predicción del modelo.	33
4.4	Importancia SHAP media ($ \text{SHAP} $) agregada por dimensión creativa. Las barras representan la contribución promedio de cada dimensión a las predicciones del modelo Random Forest.	34

4.5	Convergencia entre OLS (coeficiente ponderado por prevalencia) y SHAP (SHAP promedio) a nivel de categoría individual ($n = 34$). La correlación de Spearman es $\rho = 0,74$ ($p < 0,001$).	35
-----	---	----

Índice de cuadros

4.1	Coeficientes OLS estadísticamente significativos ($p < 0,05$). Variable dependiente: $\log(\text{CTR})$. Errores estándar HC1.	30
4.2	Clasificación de categorías creativas por convergencia entre modelos . .	36
A.1	Tabla de acrónimos utilizados en el trabajo	47
A.2	Resultados completos del modelo OLS (variable dependiente: $\log(\text{CTR})$, errores estándar HC1)	48

1. Introducción

El *paid social*, el canal de marketing que consiste en distribuir contenido publicitario pago¹ en redes sociales y que permite llegar a audiencias micro-segmentadas, ha pasado de ser un canal secundario en una estrategia de marketing, a uno de los ejes principales de cualquier mix de medios. En Estados Unidos, la publicidad en redes sociales absorberá más de una cuarta parte del gasto total en medios para 2027 ([eMarketer, 2024](#)), mientras que las proyecciones globales sitúan el desembolso específico en social media cerca de USD \$433.000 millones en 2030 ([Digital Silk, 2025](#)). Para las plataformas de redes sociales, todo esto se traduce en récords de ingresos: Meta declaró USD \$46,6 mil millones en ingresos publicitarios en el segundo trimestre de 2025 ([Meta Platforms, 2025](#)) y Alphabet/Google reportó USD \$66,9 mil millones en el primer trimestre de 2025 ([Schwartz, 2025](#)). Para las marcas, paid social representa el entorno donde sus audiencias ya pasan más de dos horas diarias (o más dependiendo del demográfico) y donde los algoritmos permiten optimizar cada dólar invertido en tiempo real.

En particular, TikTok, pese a los litigios y enfrentamientos con el gobierno chino, se ha posicionado como un actor clave en este crecimiento. La plataforma superó los 1.000 millones de usuarios a nivel mundial en 2025 (duplicando su base de 2020) ([Backlinko, 2025](#)) y el usuario promedio en Estados Unidos pasa cerca de 54 minutos diarios en la aplicación ([eMarketer, 2025](#)). Aunque su participación en el mercado publicitario aún es menor frente a gigantes como Meta, el ascenso de TikTok es innegable, obligando a las marcas a adaptarse al formato de video corto y explosivo, tal cual lo reclama la audiencia de esta red social.

Para llevar a cabo una estrategia de paid social marketing, la mayoría de las marcas, o aquellas que no cuentan con equipos internos especializados, contratan a agencias creativas bajo esquemas en los que una fracción significativa del costo es variable y depende directamente del resultado del anuncio. En este modelo, donde la facturación del servicio queda atada en buena parte al *spend*, o inversión publicitaria por parte de la marca, la agencia creativa sólo cobra si el anuncio consigue resultados concretos, de modo que su modelo de negocio y su supervivencia financiera queda atada a entregar piezas que realmente conviertan (o *performen* como se lo conoce en la jerga). Por eso

¹Todas aquellas actividades publicitarias que no son pagas se las conoce en la jerga como “Organic”. Un ejemplo de actividades orgánicas serían los posteos en el feed referenciando a algún producto o marca. También entran en este contexto las acciones con influencers, actores reconocidos en una industria por su influencia sobre una audiencia. La idea del orgánico es que el contenido se distribuye con un algoritmo que es distinto al que está detrás de las campañas publicitarias pagas.

se lo conoce también como *performance marketing*, porque el negocio está atado a la performance del anuncio. Si el anuncio no convierte, la agencia no gana. En este modelo de marketing obsesionado con resultados, cada elemento de la campaña enfrenta una intensa presión de optimización. La segmentación de audiencia y el alcance se han automatizado gracias a la inteligencia artificial de las plataformas, por lo que **el elemento diferencial bajo control del anunciante es la pieza creativa, es decir, el anuncio mismo y la creatividad dentro de él**. En otras palabras, con la compra de medios, o *media buying*, prácticamente estandarizado y optimizado en tiempo real por algoritmos, la calidad y diversidad del anuncio en sí se convierte en el principal campo de batalla. De allí surge la necesidad de producir anuncios capaces de destacar en el feed, resonar con su público objetivo y maximizar las acciones deseadas.

1.1. La batalla por la atención en el feed

En el feed de TikTok el usuario se desplaza (*scrollea*) casi sin pensar, y las investigaciones de neuromarketing muestran que basta un cuarto de segundos de exposición para que una persona decida si detiene el pulgar o sigue deslizando ([Facebook IQ, 2016](#)). Este lapso brevísimo dio origen al concepto de contenido *scroll-stopper*, piezas creadas para frenar ese movimiento y mantener la atención hasta que se pueda transmitir el mensaje y lograr la acción deseada, ya sea exponer un link hacia una página web, o directamente a la acción de compra. La métrica más sencilla y extendida para evaluar ese éxito es el Click Through Rate (CTR), obtenido al dividir los clics por las impresiones. Indicadores como el Hook Rate o el View Through Rate (VTR) ayudan a medir la retención temprana, pero el CTR sigue siendo el estándar en los equipos de performance por su facilidad de cálculo y comparación.

Desde la psicología cognitiva, el fenómeno se explica con el Limited Capacity Model of Motivated Mediated Message Processing (LC4MP, [Lang 2000](#)), que sostiene que la mente humana dispone de recursos atencionales finitos y los asigna según relevancia y novedad del estímulo. En *feeds* saturados de estímulos visuales y sonoros, un anuncio debe, primero, parecer orgánico, es decir, mimetizarse con el contenido nativo del usuario y, segundo, ofrecer un “pico” de novedad o recompensa para ganar prioridad en la cola atencional (*orienting response*).

1.2. Diversidad creativa como palanca de micro-segmentación

Ante la escasez de atención, la diversidad creativa emerge como estrategia para ofrecer al algoritmo de distribución múltiples “llaves” capaces de abrir micro-segmentos distintos. Un análisis interno de Meta comprobó que los ad sets² con 3 a 10 creatividades obtuvieron un 46 % menos de Costo Por Adquisición (CPA³) frente a los que empleaban una sola pieza ([Meta for Business, 2024a](#)). Un informe posterior mostró que basta incorporar dos creatividades visualmente diferenciadas para recortar el CPA en 4,6 % ([Meta for Business, 2024b](#)). Estos hallazgos refuerzan la intuición clásica del *direct response*, concepto sobre el cual se profundizará más adelante: más variedad no implica más volumen de anuncios, sino una mejor correlación entre pieza y audiencia, al entregar al algoritmo mayor amplitud para experimentar y optimizar el delivery.

1.3. El aporte del marco ReadySet CDS

Ready Set es una agencia de performance marketing fundada en 2019 en Estados Unidos y especializada en marcas de industrias reguladas. A fin de disponibilizar a los clientes una forma sencilla, pero rigurosa y precisa, de diagnosticar la fatiga creativa⁴, desarrolló el Creative Diversity Score (CDS), un índice que va de 0 a 100 construido sobre seis dimensiones operativas que convierte la abstracción de “variedad” en una métrica accionable ([Ready Set, 2025](#)). De este modo, el puntaje CDS refleja cuán diversa es una estrategia creativa en un sentido integral.

Desde su lanzamiento, el CDS se usa como KPI interno de la empresa para auditar más de 60.000 anuncios. Las seis dimensiones que componen el CDS abarcan distintos aspectos de las campañas publicitarias, tales como: la variedad de formatos y estilos de producción utilizados, la diversidad de temáticas y conceptos creativos abordados, la sofisticación de la estrategia de segmentación y funnel aplicada, la amplitud de canales y ubicaciones donde corren los anuncios, la diversidad del elenco o personas mostradas en las creatividades (casting), y la frecuencia de rotación o renovación de los anuncios.

²Un ad set (conjunto de anuncios) es el nivel de campaña que define audiencia/segmentación, presupuesto, calendario, ubicaciones y objetivo de optimización, y dentro de él se alojan los anuncios (creatividades).

³El CPA mide cuánto cuesta, en promedio, lograr una conversión objetivo (p. ej., compra, lead, registro) en una campaña. Fórmula: $CPA = \text{gasto publicitario atribuido} / \text{número de conversiones atribuidas}$.

⁴La fatiga creativa se refiere al fenómeno en el que una audiencia, tras ver repetidamente los mismos anuncios o elementos creativos, empieza a desconectarse y a ignorarlos, provocando una caída en el rendimiento de la campaña.

En síntesis, dentro de un negocio donde el ingreso de la agencia depende del rendimiento y el éxito de la marca en las conversiones, capturar atención es clave y diversificar inteligentemente proporciona al algoritmo la materia prima para lograrlo.

La presente investigación propone y valida un proceso empírico para identificar, dentro del marco CDS, qué dimensiones creativas están más asociadas con el CTR en TikTok. La demostración se realiza sobre las tres dimensiones observables en el corpus (*Creative Theme*, *Creative Concept* y *Talent Type*), pero la metodología es replicable con cualquier dataset que incluya varianza en las dimensiones restantes, aportando lineamientos accionables para equipos de performance que viven, literalmente, de cada punto porcentual ganado.

El trabajo aporta tanto a la teoría como a la práctica. Se amplía la literatura sobre creatividad publicitaria y performance al ofrecer evidencia cuantitativa sobre el rol de la diversidad creativa en el contexto de TikTok. Además, se brindan a las marcas recomendaciones concretas sobre qué estrategias creativas, entre las muchas posibles, están más estrechamente asociadas con un mayor CTR. En los capítulos que siguen, se repasa la literatura y los marcos conceptuales relevantes (Capítulo 2), se describen los datos y la metodología, incluyendo el proceso de etiquetado bajo el marco CDS (Capítulo 3), se presentan los resultados con apoyo visual (Capítulo 4), y se discuten las implicancias prácticas, las limitaciones del estudio y las líneas futuras de investigación (Capítulo 5).

1.4. Pregunta de investigación y objetivos

1.4.1. Pregunta de investigación

¿Es posible construir una metodología cuantitativa y replicable para identificar qué dimensiones del marco Creative Diversity Score (CDS) están más asociadas con el CTR de anuncios en TikTok, y qué revela esa metodología al aplicarla sobre un corpus representativo de la plataforma?

1.4.2. Objetivo principal

Proponer y validar una metodología cuantitativa replicable para rankear las dimensiones del CDS según su asociación con el CTR en TikTok, y demostrar su aplicación sobre 578 Top Ads del primer trimestre de 2025. La metodología emplea dos modelos con roles complementarios: Random Forest con valores SHAP para identificar qué dimensiones creativas tienen mayor importancia predictiva, y OLS para cuantificar la

dirección y magnitud de la asociación de cada categoría dentro de esas dimensiones. El análisis se circunscribe a tres de las seis dimensiones del marco (*Creative Theme*, *Creative Concept* y *Talent Type*), las observables en el corpus. Las tres restantes son excluidas por razones estructurales (ver Sección 3.1). Los resultados específicos son válidos para el período analizado. La contribución principal del trabajo es el *pipeline* analítico, diseñado para repetirse con cualquier dataset actualizado.

1.4.3. Objetivos secundarios

1. Describir la distribución del CTR según cada dimensión de diversidad creativa analizada.
2. Describir qué categorías dentro de cada dimensión del CDS presentan mayor o menor CTR medio en un análisis univariado, como primer paso exploratorio antes del análisis multivariado.
3. Aplicar un modelo Random Forest con valores SHAP para identificar qué dimensiones creativas tienen mayor importancia predictiva sobre el CTR, sin necesidad de asumir una forma funcional entre predictores y respuesta (Lundberg and Lee, 2017; Strobl et al., 2007).
4. Aplicar un modelo OLS con contrastes de desviación para cuantificar la dirección y magnitud de la asociación de cada categoría creativa con el CTR, expresando los resultados como variaciones porcentuales interpretables para equipos de estrategia creativa. La convergencia entre el ranking de importancia del RF y los coeficientes OLS, verificada mediante correlación de Spearman, valida que ambos instrumentos capturan la misma señal empírica (Breiman, 2001b; Mullainathan and Spiess, 2017).

1.4.4. Hipótesis

H_1 : Al menos una de las tres dimensiones analizadas del CDS (*Creative Theme*, *Creative Concept* y *Talent Type*) tiene importancia predictiva significativa sobre el CTR en TikTok según el modelo Random Forest, y el modelo OLS identifica coeficientes estadísticamente significativos en categorías de esa misma dimensión, incluso al controlar por variables de configuración de campaña.

H_0 : Las dimensiones del CDS analizadas no presentan importancia predictiva sobre el CTR según el modelo Random Forest, o el modelo OLS no encuentra coeficientes estadísticamente significativos en ninguna categoría de esas dimensiones una vez controlado por tipo de campaña y duración del video.

2. Revisión de la Literatura

2.1. Estrategia creativa y rendimiento en plataformas digitales

La investigación académica sobre publicidad digital ha prestado atención creciente a la relación entre los atributos del contenido creativo y el rendimiento de los anuncios. En plataformas como TikTok, donde el algoritmo de distribución actúa como intermediario entre la pieza publicitaria y la audiencia, las características formales y narrativas del anuncio tienen un impacto medible sobre métricas de performance.

[Yang et al. \(2025\)](#) ofrecen evidencia empírica directa sobre este fenómeno: su análisis de campañas con influencers en TikTok muestra que los patrones de engagement (me gusta, comentarios, reproducciones completas) están fuertemente determinados por atributos del contenido, entre ellos el tono narrativo, la autenticidad percibida y la integración del producto en la historia. Más aún, esos mismos patrones de engagement se traducen en ventas incrementales medibles. El hallazgo central es que no basta con que un influencer tenga audiencia. Lo que determina la conversión es la estructura del video y la forma en que el producto aparece dentro de la narrativa. Esto implica que la creatividad, entendida como la configuración de elementos audiovisuales y narrativos de la pieza, no es un factor decorativo sino funcional: distintas configuraciones producen distintos resultados de performance.

En una línea complementaria, [Meng et al. \(2024\)](#) estudian el impacto de las características del contenido de los anuncios de video corto en TikTok sobre el comportamiento de compra del consumidor. Los autores identifican dimensiones específicas del contenido (la presencia de elementos informativos versus emocionales, la duración efectiva del mensaje y la claridad del llamado a la acción) como predictores significativos de la intención y el comportamiento de compra. Este trabajo es particularmente relevante para la presente investigación porque opera a nivel de la pieza creativa individual, en lugar de agregar a nivel de campaña o anunciante, lo que permite una comparación más directa con la metodología aquí adoptada.

En conjunto, esta literatura sostiene una premisa central: los atributos observables del contenido creativo no son accesorios sino funcionales. Distintas configuraciones creativas producen distintos niveles de engagement y conversión en la misma plataforma y para audiencias similares. Identificar cuáles de esas configuraciones tienen mayor

asociación con métricas de performance es precisamente el problema que motiva este trabajo.

2.2. Métricas clave: CTR y CPA en campañas de respuesta directa

En el contexto del performance marketing, la evaluación del rendimiento publicitario se articula en torno a un conjunto reducido de métricas que conectan la exposición al anuncio con la acción del consumidor. Las dos más relevantes para este trabajo son el Click Through Rate (CTR) y el Costo Por Adquisición (CPA), que operan en distintos eslabones del embudo de conversión y pueden responder de manera diferente ante la misma estrategia creativa.

El CTR mide la proporción de usuarios que hacen clic en el anuncio respecto al total de impresiones servidas. Es una métrica de la parte alta del embudo (*upper funnel*): captura la eficacia del anuncio para capturar atención y generar intención de exploración, pero no garantiza que esa intención se traduzca en una conversión posterior. Su fortaleza reside en que es calculable en tiempo real, comparable entre campañas y plataformas, y refleja de manera directa la respuesta inicial del usuario ante la pieza creativa. En TikTok, el CTR reviste especial importancia porque el formato de video corto impone una ventana de atención estrecha: un anuncio que no logra capturar la atención en los primeros segundos nunca llega a comunicar su propuesta de valor (Salminen et al., 2024).

El CPA, en cambio, es una métrica de la parte baja del embudo (*lower funnel*): mide el costo promedio de cada conversión atribuida a la campaña, ya sea una compra, un registro o una descarga. A diferencia del CTR, el CPA integra no solo la eficacia creativa sino también la calidad de la segmentación, la experiencia en la página de destino y la competitividad de la oferta. Un anuncio puede tener CTR alto y CPA elevado si atrae muchos clics de usuarios sin intención real de compra, o CTR bajo y CPA eficiente si la audiencia alcanzada, aunque reducida, tiene alta propensión a convertir. Esta asimetría implica que optimizar exclusivamente por CTR no garantiza eficiencia en la conversión (Kantar Media, 2023).

La relación entre ambas métricas es el objeto de estudio del marketing de respuesta directa (*direct response*), una tradición que busca conectar de manera cuantificable cada acción del usuario con el mensaje que la provocó. En este marco, la pieza creativa no se evalúa por criterios estéticos sino por su capacidad de mover al usuario de la exposición a la acción. Las marcas que operan bajo esquemas de comisión variable tienen un incentivo claro para entender esta relación: invertir en creatividades que

maximizan el CTR solo tiene sentido si ese CTR se traduce, en última instancia, en reducciones del CPA ([Kantar Media, 2023](#)).

En el presente estudio se adopta el CTR como variable dependiente principal por dos razones prácticas. Primero, es la métrica disponible en el dataset de TikTok Top Ads analizado, ya que el CPA requiere acceso a datos post-clik que no están disponibles en fuentes públicas. Segundo, el CTR es la métrica más directamente atribuible a la pieza creativa: a diferencia del CPA, su variación responde principalmente a atributos del anuncio y no a factores de la segmentación o de la página de destino. Esto lo convierte en un proxy razonablemente válido de la eficacia creativa, el concepto central que esta investigación busca operacionalizar.

2.3. Fatiga creativa y necesidad de diversidad

La fatiga creativa es uno de los fenómenos más documentados y, al mismo tiempo, más subestimados en la práctica del performance marketing. Se produce cuando una audiencia ve repetidamente el mismo anuncio, o versiones muy similares de él, y comienza a ignorarlo: la atención se reduce, el CTR cae y el CPA sube, erosionando la eficiencia de la campaña sin que haya cambiado ningún parámetro de segmentación ni de presupuesto ([Singular, 2025](#)).

El mecanismo subyacente está bien establecido en la psicología cognitiva. La *orienting response* (respuesta de orientación), que se activa involuntariamente ante estímulos novedosos, se habitúa con la exposición repetida: un estímulo que inicialmente capturarba la atención deja de hacerlo una vez que el sistema cognitivo lo clasifica como conocido y no relevante. En el contexto del feed de TikTok, donde el algoritmo aprende los patrones de consumo del usuario y tiende a reexponer anuncios que ya han producido cierta interacción, este mecanismo opera con particular rapidez ([Zhang et al., 2025](#)). Las plataformas de video corto potencian este efecto porque el formato inmersivo y de alta frecuencia de impresiones acelera el ciclo de habituación respecto a los formatos estáticos o de banner.

Los síntomas de la fatiga creativa en datos de campaña son reconocibles: una degradación gradual del CTR y del Hook Rate (proporción de usuarios que ven los primeros tres segundos del video) que no se explica por cambios en la segmentación ni en el presupuesto, acompañada de un aumento correlativo del CPA ([Ad-Lib.io, 2022](#)). Las plataformas han desarrollado alertas automáticas para detectar este fenómeno, pero la respuesta correctiva (reemplazar o rotar las piezas creativas) requiere tener nuevas creatividades disponibles para hacer el reemplazo en el momento adecuado.

Esta restricción operativa es la que hace que la diversidad creativa no sea simple-

mente una buena práctica sino una condición de sustentabilidad para las campañas de performance en entornos de alto volumen de impresiones. Una campaña con pocas piezas creativas, por más que esas piezas sean de alta calidad en el momento de su lanzamiento, está estructuralmente expuesta a la fatiga: eventualmente agota su capacidad de generar atención en la audiencia disponible. Diversificar el repertorio creativo no garantiza que todas las piezas tengan buen rendimiento, pero sí garantiza que el desempeño agregado de la campaña sea más robusto ante la inevitable habituación de la audiencia ([Singular, 2025](#)).

2.4. Diversidad creativa y Creative Diversity Score (CDS)

La diversidad creativa, como concepto, designa la variedad en los atributos formales, narrativos y estratégicos de las piezas publicitarias dentro de una campaña o portafolio. A diferencia de la creatividad entendida como originalidad o calidad individual de un anuncio, la diversidad creativa es una propiedad del conjunto: un portafolio puede estar compuesto por piezas de alta calidad individual y ser, no obstante, poco diverso si todas ellas comparten los mismos formatos, tonos y estructuras narrativas ([Khan et al., 2025](#)).

La evidencia empírica sobre los efectos de la diversidad creativa en performance proviene principalmente de experimentos y análisis internos de plataformas. Meta ha publicado resultados consistentes en esta dirección: los ad sets que contienen entre 3 y 10 creatividades distintas obtuvieron en promedio un 46 % menos de CPA que los que utilizaban una sola pieza, controlando por presupuesto y audiencia ([Meta for Business, 2024a](#)). Un análisis posterior más granular mostró que basta incorporar dos creatividades visualmente diferenciadas para producir una reducción del CPA del 4,6 % ([Meta for Business, 2024b](#)). El mecanismo propuesto es que la mayor variedad de piezas entrega al algoritmo de distribución más opciones para experimentar, identificar qué subconjunto de la audiencia responde mejor a cada tipo de contenido y optimizar el delivery en consecuencia.

Desde la investigación académica, [Khan et al. \(2025\)](#) aportan evidencia sobre cómo la diversidad en las representaciones dentro de los anuncios (diversidad de personas, situaciones y contextos mostrados) afecta la percepción de variedad de la marca y los resultados de marca a largo plazo. Aunque el foco de ese estudio es la diversidad de representaciones y no exactamente la diversidad creativa en el sentido del CDS, el mecanismo propuesto es análogo: la variedad señala amplitud de relevancia, lo que amplía el segmento de audiencia que se identifica con el mensaje publicitario.

El Creative Diversity Score (CDS) de Ready Set operacionaliza este concepto en seis dimensiones medibles ([Ready Set, 2025](#)): *Creative Theme* (temática o concepto narrativo general), *Creative Concept* (tipo específico de ejecución dentro de una temática), *Talent Type* (tipo de persona o presencia humana en el anuncio), *Production Style* (estilo de producción audiovisual), *Funnel Stage* (etapa del embudo de conversión a la que apunta el anuncio) y *Platform Placement* (ubicación y formato de distribución). Cada dimensión es evaluada de forma independiente, y el índice global, que va de 0 a 100, refleja cuán equilibrada es la distribución de piezas entre las categorías posibles de cada dimensión.

2.4.1. Ejemplo de análisis usando el CDS

Para ilustrar cómo opera el CDS en la práctica, consideremos un portafolio hipotético de 20 anuncios en TikTok donde todos los videos tienen humor como *Creative Theme*, presentan al fundador de la marca como *Talent Type* y usan un estilo de producción de alta fidelidad. Este portafolio obtendría un puntaje muy bajo en las dimensiones de tema, talento y estilo de producción, independientemente de la calidad individual de cada pieza: hay poca diversidad en esas dimensiones. Un usuario que no conecta con el humor como registro comunicacional, o que prefiere contenido con personas más parecidas a él, quedará sistemáticamente sin una “llave” que abra su atención.

En contraste, un portafolio con la misma cantidad de piezas pero que distribuye equitativamente entre humor, narrativas de vida cotidiana, contenido anclado en eventos y demostraciones de producto, e incorpora distintos tipos de talento (fundador, usuarios reales, creadores de contenido), obtendría un CDS más alto en esas dimensiones. El algoritmo de distribución de TikTok tiene entonces más opciones para testear qué combinación resuena con cada micro-segmento, y el portafolio en su conjunto tiene menor exposición al riesgo de fatiga creativa ([Ready Set, 2025](#)).

Es importante subrayar que el CDS no mide la calidad de cada pieza individual sino la diversidad del conjunto. Un portafolio con CDS alto puede incluir piezas de bajo rendimiento, pero la premisa es que el desempeño agregado de un portafolio diverso es más robusto y sostenible en el tiempo que el de un portafolio concentrado, aunque las piezas individuales de este último puedan ser mejores en aislamiento ([Meta for Business, 2024a](#)).

2.4.2. Hallazgos principales

La evidencia acumulada sobre el CDS, si bien proviene mayormente de fuentes de industria y no de estudios sometidos a revisión por pares, es consistente en su

dirección: los portafolios con mayor diversidad creativa, medida por el CDS, tienden a obtener mejores resultados en métricas de performance (Ready Set, 2025). Ready Set reporta que en su base de más de 60.000 anuncios auditados, un CDS alto se asocia consistentemente con menores tasas de fatiga creativa y mayor eficiencia en el CPA a largo plazo.

Sin embargo, esta evidencia agrega a nivel de portafolio y no descompone la contribución de cada dimensión del CDS al resultado observado. No es evidente, a priori, que las seis dimensiones tengan igual importancia para el CTR: es plausible que variar el *Creative Theme* tenga un impacto muy distinto que variar el *Production Style*, por ejemplo. La identificación de cuáles dimensiones del CDS tienen mayor asociación con el CTR, es decir, cuáles son las “llaves” más efectivas para capturar atención, es precisamente la brecha empírica que este trabajo busca cubrir.

2.5. Desafíos metodológicos: causalidad vs. asociación

Establecer que las dimensiones del CDS *causan* variaciones en el CTR es una afirmación empíricamente más exigente que documentar una *asociación* entre ellas. La distinción no es meramente filosófica: tiene consecuencias directas sobre qué tipo de recomendaciones puede derivarse legítimamente de los datos y sobre la confianza con la que esas recomendaciones pueden generalizarse.

Los datos observacionales, como los utilizados en este estudio, presentan una dificultad estructural para la identificación causal: los anuncios no se asignan aleatoriamente a las categorías del CDS. Un anunciante que elige usar narrativas de vida cotidiana como *Creative Theme* probablemente también está haciendo otros ajustes en su estrategia (selección de audiencia, presupuesto, timing) que podrían explicar por qué esos anuncios tienen mayor CTR. En ausencia de aleatorización, es difícil separar el efecto del atributo creativo del efecto de las variables de confusión no observadas (Cunningham, 2021).

Este problema es familiar en la literatura de publicidad digital: los anunciantes más sofisticados tienden simultáneamente a invertir más en producción creativa, segmentar mejor y elegir momentos más oportunos para sus campañas (Yang et al., 2025). Todo esto se correlaciona con mejores métricas, lo que hace difícil aislar cuánto del resultado se debe a la creatividad y cuánto a los demás factores. Esta simultaneidad de tratamientos es una forma de sesgo de selección que los modelos observacionales no pueden eliminar de raíz (Cunningham, 2021).

2.5.1. Ejemplo de experimento para identificar la relación causal

El diseño ideal para identificar el efecto causal de las dimensiones del CDS sobre el CTR sería un experimento aleatorizado controlado. La lógica sería la siguiente: para un conjunto de marcas con características similares (industria, presupuesto, audiencia objetivo), se asignaría aleatoriamente qué *Creative Theme* utilizar durante un período determinado. Dado que la asignación es aleatoria, las diferencias sistemáticas en CTR observadas entre los grupos solo podrían atribuirse al tipo de tema creativo asignado, y no a diferencias preexistentes entre los anunciantes (Cunningham, 2021).

En la práctica, sin embargo, este diseño enfrenta obstáculos considerables. Las marcas rara vez están dispuestas a subordinar sus decisiones creativas a la aleatorización, los presupuestos y las estrategias varían durante el período experimental, y los efectos de interacción entre dimensiones del CDS hacen que el espacio experimental sea muy grande para diseños factoriales completos. Una alternativa más realista en entornos de industria sería un análisis de diferencias en diferencias (DiD) que compare el CTR de las mismas marcas antes y después de un cambio de perfil creativo, usando como grupo de control a marcas que no modificaron su estrategia durante ese período (Cunningham, 2021).

Dado que ninguna de estas aproximaciones experimentales es viable con los datos disponibles en este estudio, el alcance de las conclusiones es necesariamente correlacional. Los resultados reportados en los capítulos siguientes describen qué dimensiones del CDS están *asociadas* con mayor CTR en el dataset analizado y no constituyen evidencia de que esas dimensiones aumenten el CTR de manera causal ni que los efectos sean generalizables a todos los contextos y períodos. Esta limitación es inherente al diseño y se reconoce explícitamente a lo largo de la interpretación de los resultados.

2.6. Marco estadístico para el análisis de atributos creativos

2.6.1. Regresión OLS para variables de respuesta categórica: supuestos, limitaciones y justificación

El modelo de mínimos cuadrados ordinarios (OLS) descansa sobre un conjunto de supuestos cuya validez condiciona la confiabilidad de la inferencia. Fox (2016) los ordena jerárquicamente según su impacto en la inferencia: la correcta especificación de la forma funcional y la ausencia de multicolinealidad perfecta son los más críticos,

la homocedasticidad es importante pero tratable, y la normalidad de los errores es la condición menos exigente cuando el tamaño muestral es suficientemente grande (Fox, 2016, Cap. 5).

Codificación de variables categóricas y trampa de las variables indicadoras

La inclusión de variables categóricas mediante variables indicadoras (*dummies*) requiere que una categoría sea excluida del modelo para evitar multicolinealidad perfecta con el intercepto, fenómeno conocido como la trampa de las variables indicadoras. Fox (2016, p. 163) establece que al representar una variable categórica con k niveles se generan exactamente k indicadoras cuya suma es idéntica a la constante, haciendo que la matriz de diseño sea de rango incompleto. La solución estándar consiste en omitir una categoría de referencia, de modo que todos los coeficientes restantes expresen la desviación de esa categoría respecto al intercepto global.

En el presente análisis se utiliza *sum-to-zero contrasts*, una codificación que distribuye los coeficientes de cada variable categórica alrededor del promedio global. Esto permite interpretar cada coeficiente como la desviación de esa categoría respecto a la gran media global, lo cual es conceptualmente más natural para comparar el desempeño relativo de dimensiones creativas sin que los resultados dependan de la elección arbitraria de una categoría de referencia (Fox, 2016, Cap. 8).

Variable dependiente acotada y transformación logarítmica

El CTR es una proporción acotada en el intervalo $(0, 1)$, lo que plantea una incompatibilidad parcial con los supuestos del OLS lineal: las predicciones pueden caer fuera del rango válido y la varianza de los errores tiende a aumentar a medida que el valor predicho se aproxima a los extremos del intervalo. La literatura propone alternativas diseñadas específicamente para este tipo de variable dependiente. Papke and Wooldridge (1996) desarrollan el estimador de máxima verosimilitud para respuesta fraccional (*fractional logit*), que garantiza predicciones en $(0, 1)$ y es asintóticamente eficiente. Ferrari and Cribari-Neto (2004) proponen la regresión beta, un modelo que parametriza directamente la media y la dispersión de una distribución beta, siendo especialmente adecuado cuando los datos presentan asimetría dentro del intervalo.

En este trabajo se aplica la transformación logarítmica $y^* = \log(\text{CTR})$, que resuelve el problema de dos maneras complementarias. En primer lugar, estabiliza la varianza: el CTR presenta una asimetría derecha pronunciada ($\text{skewness} = 6,78$) que se reduce a 1,87 tras la transformación, aproximando la distribución a una forma más simétrica (Fox, 2016, Cap. 12). En segundo lugar, neutraliza el riesgo de predicciones fuera de rango dentro del soporte de los datos observados. La elección del logaritmo puede

fundamentarse formalmente mediante el procedimiento de Box–Cox: en el límite $\lambda \rightarrow 0$, la familia de transformaciones potencia de Box–Cox converge a la transformación logarítmica (Fox, 2016, Cap. 12), lo que otorga respaldo empírico a esta decisión cuando el parámetro estimado es cercano a cero.

El objetivo del modelo no es la predicción puntual de CTR sino la estimación del *ranking* de importancia de las dimensiones creativas. En este contexto, la pérdida de interpretabilidad directa de los coeficientes (que ahora expresan efectos multiplicativos sobre el CTR en escala original) es compensada por la mayor validez de los supuestos del modelo.

Heterocedasticidad y errores estándar robustos

Aun con la transformación logarítmica, los datos de CTR pueden exhibir varianza no constante de los errores. Para mitigar el impacto de la heterocedasticidad sobre la inferencia, se reportan errores estándar robustos siguiendo el estimador de la matriz de covarianza consistente con heterocedasticidad propuesto por White (1980), en su versión HC1 con corrección de grados de libertad. Este estimador produce estadísticos t y valores p asintóticamente válidos sin necesidad de suponer varianza constante de los errores (Fox, 2016, Cap. 12).

2.6.2. Random Forest como complemento no paramétrico: importancia de variables e interpretabilidad

El algoritmo de Random Forest, introducido por Breiman (2001a), construye un ensamble de árboles de decisión independientes cuyas predicciones se promedian para obtener la predicción final. Cada árbol se ajusta sobre una muestra con reemplazo del conjunto de datos original (*bootstrap aggregating* o *bagging*), y en cada nodo de división solo se evalúa un subconjunto aleatorio de variables predictoras. Esta doble fuente de aleatoriedad reduce la correlación entre los árboles del ensamble, lo que permite que el promedio de sus predicciones tenga menor varianza que cualquier árbol individual sin incrementar el sesgo (Breiman, 2001a).

La propiedad fundamental que motiva el uso del Random Forest en este análisis es su ausencia de supuestos sobre la forma funcional de la relación entre las variables predictoras y la variable dependiente. Mientras el OLS impone linealidad aditiva, el Random Forest es capaz de capturar interacciones entre variables, relaciones no monótonas y umbrales de respuesta de manera implícita, sin que el investigador deba especificarlos de antemano (Hastie et al., 2009, Cap. 15).

Sesgo en la importancia de variables por impureza de Gini

Una limitación relevante del Random Forest en el contexto de este análisis concierne a la métrica de importancia de variables por defecto: la disminución media de impureza (*Mean Decrease Impurity*, MDI), basada en el índice de Gini. Strobl et al. (2007) demuestran que esta métrica exhibe sesgo sistemático hacia variables con mayor número de categorías o mayor varianza, independientemente de su verdadera capacidad predictiva. Este sesgo es directamente relevante en el presente estudio, dado que las tres dimensiones creativas tienen cardinalidades muy distintas: `creative_concept` cuenta con hasta 20 categorías mientras que `talent_type` tiene 7. Una comparación de importancias basada en MDI tendría sesgo *a priori* a favor de `creative_concept`, distorsionando el ranking de dimensiones.

Strobl et al. (2008) extienden este análisis y muestran que la importancia por permutación (*permutation importance*) también puede verse afectada cuando las variables predictoras presentan correlación entre sí, proponiendo la importancia condicional como solución. En el presente caso, es razonable suponer que `creative_theme` y `creative_concept` están correlacionadas (un anuncio de tema humorístico tiende a emplear ciertos tipos de concepto), por lo que esta caveat se reconoce como limitación del análisis y se reporta en la sección correspondiente.

SHAP: interpretabilidad basada en teoría de juegos

Para superar las limitaciones de las métricas de importancia tradicionales, se emplean los valores SHAP (*SHapley Additive exPlanations*), propuestos por Lundberg and Lee (2017). SHAP asigna a cada variable una contribución marginal a la predicción individual de cada observación, derivada de los valores de Shapley de la teoría de juegos cooperativos. La contribución de la variable j para la observación i se define como el promedio ponderado del efecto marginal de incorporar j al modelo a través de todas las posibles coaliciones de variables.

La ventaja principal de SHAP sobre MDI y la importancia por permutación es doble. Primero, es una medida de importancia *local*: la contribución de cada variable se calcula observación a observación, y la importancia global se obtiene como el promedio del valor absoluto de las contribuciones individuales ($|\phi_j|$). Esto hace que la métrica global incorpore intrínsecamente la prevalencia de cada categoría en el dataset: una categoría con efecto puro elevado pero muy pocas observaciones contribuirá poco al promedio global de SHAP, lo que resulta en una medida más representativa del impacto real sobre el conjunto de datos. Segundo, SHAP satisface un conjunto de propiedades axiomáticas deseables (eficiencia, simetría, linealidad y variable nula) que garantizan la unicidad y coherencia de la descomposición (Lundberg and Lee, 2017).

En el presente análisis, los valores SHAP se utilizan tanto para determinar la importancia de cada dimensión creativa (a nivel agregado, comparando las tres dimensiones) como para interpretar la dirección del efecto de cada categoría individual sobre el CTR predicho.

2.6.3. La complementariedad entre enfoques lineales y no lineales

La decisión de emplear simultáneamente un modelo OLS y un Random Forest en esta investigación se enmarca en un debate metodológico más amplio sobre las dos culturas del modelado estadístico, articulado por Breiman (2001b). Breiman distingue entre la cultura del *modelado de datos* (*data modeling culture*), que asume una forma funcional estocástica para generar los datos y estima sus parámetros, y la cultura del *modelado algorítmico* (*algorithmic modeling culture*), que trata la relación entre variables predictoras y respuesta como una caja negra y busca la función que mejor la aproxima empíricamente. La regresión OLS es el ejemplo canónico de la primera cultura, y el Random Forest, de la segunda.

Breiman (2001b) argumenta que la adopción exclusiva del modelado de datos lleva a asumir modelos que frecuentemente no reflejan la estructura real de los datos, produciendo estimaciones sesgadas y conclusiones dudosas cuando los supuestos no se cumplen. Al mismo tiempo, reconoce que los modelos algorítmicos sacrifican interpretabilidad: sus predicciones son precisas pero difíciles de traducir en reglas de acción concretas para los practicantes.

Varian (2014), escribiendo desde la perspectiva de la economía aplicada, llega a una conclusión análoga: las técnicas de aprendizaje automático son superiores al OLS para tareas de predicción y para descubrir relaciones no lineales complejas en datos de alta dimensionalidad, pero el OLS retiene ventajas decisivas cuando el objetivo es la estimación de parámetros con validez inferencial. Varian propone que la combinación de ambos enfoques (usando ML para selección de variables o detección de no linealidades, y OLS para la cuantificación de efectos) produce análisis más robustos que cualquiera de los dos aisladamente.

Mullainathan and Spiess (2017) formalizan esta complementariedad distinguiendo entre dos problemas estadísticos fundamentalmente distintos: la predicción ($\hat{y}$) y la estimación ($\hat{\beta}$). El aprendizaje automático está optimizado para minimizar el error de predicción fuera de muestra, pero no produce estimadores insesgados de coeficientes causales ni ofrece errores estándar con interpretación probabilística directa. La econometría clásica, en cambio, está diseñada para estimar $\hat{\beta}$ con propiedades estadísticas conocidas, aunque al precio de supuestos de forma funcional que pueden no ser válidos.

Los autores concluyen que ambos enfoques son complementarios, no competidores, y que su uso conjunto enriquece el análisis.

En el presente estudio, esta complementariedad se operacionaliza de manera secuencial. El Random Forest, a través de los valores SHAP, identifica primero qué dimensiones creativas tienen mayor importancia predictiva sobre el CTR, sin imponer supuestos de linealidad ni aditividad ([Mullainathan and Spiess, 2017](#)). El OLS opera luego sobre esas dimensiones para cuantificar la dirección y magnitud de la asociación de cada categoría, produciendo coeficientes interpretables y comunicables a los *creative strategists* en términos de variación porcentual del CTR. La convergencia entre ambos instrumentos, verificable mediante la correlación de Spearman entre el ranking de importancia del RF y los coeficientes OLS ponderados por prevalencia, valida que los dos enfoques capturan la misma señal empírica ([Breiman, 2001b](#)). Cuando divergen, esa divergencia delimita el alcance del modelo lineal y sugiere posibles no linealidades que el OLS no puede capturar.

3. Metodología

3.1. Recolección y anotación de datos

El dataset utilizado en este trabajo está compuesto por 578 anuncios extraídos de TikTok Top Ads, una biblioteca pública provista por TikTok que exhibe los anuncios con mejor desempeño histórico en la plataforma, filtrados para el primer trimestre de 2025. La selección se restringió a anuncios en inglés publicados en el mercado de Estados Unidos, con el objetivo de mantener homogeneidad cultural y lingüística en el proceso de etiquetado.

Cada anuncio fue etiquetado manualmente por el autor de acuerdo con tres de las seis dimensiones del Creative Diversity Score: *Creative Theme* (temática narrativa general del anuncio), *Creative Concept* (tipo específico de ejecución dentro de esa temática) y *Talent Type* (tipo de presencia humana o figura principal en el video). Estas tres dimensiones fueron seleccionadas porque concentran la mayor variabilidad creativa observable en el dataset. Las otras tres dimensiones del CDS fueron excluidas del análisis por razones estructurales, no por descuido metodológico: (1) la dimensión de *formato y estilo de producción* no exhibe varianza en el corpus, dado que la totalidad de los anuncios corresponde a video corto nativo, el único formato disponible en TikTok Top Ads. (2) La dimensión de *canales y plataformas* tampoco varía, ya que el dataset es 100 % TikTok y medir diversidad de plataformas requeriría incorporar inventario de Meta, Google u otras redes, lo que excede el alcance de este estudio. (3) La dimensión de *rotación y renovación de creatividades* no puede medirse en un corte transversal sin fechas de publicación individuales por anuncio, dado que requeriría datos longitudinales que permitan rastrear la frecuencia de reemplazo de piezas dentro de cada portfolio. En los tres casos, la exclusión se debe a que modelar una variable constante o no observable no aporta información al análisis: solo es posible estimar el efecto de lo que varía.

El proceso de etiquetado siguió un protocolo en dos pasos. Primero, se definieron las categorías posibles para cada dimensión a partir del marco CDS de Ready Set ([Ready Set, 2025](#)), revisando los límites entre categorías en los casos ambiguos. Segundo, cada anuncio fue visualizado en su totalidad y clasificado de manera independiente en cada una de las tres dimensiones. En los casos donde el anuncio podía encuadrarse en más de una categoría, se asignó la que mejor representaba el elemento dominante de la pieza.

El dataset resultante presentó distribuciones asimétricas en algunas categorías, con

varios valores de baja frecuencia. Siguiendo la recomendación de Fox (2016, Cap. 5) de que las categorías con muy pocos casos producen estimadores inestables en modelos OLS con variables indicadoras, se estableció un umbral mínimo de 10 observaciones por categoría: las categorías con $n < 10$ fueron colapsadas en una categoría residual denominada “Other”. Tras este procedimiento, *Creative Concept* pasó de 20 a 8 categorías (7 individuales más “Other”), *Talent Type* de 8 a 7 categorías más “Other”, y *Creative Theme* mantuvo sus 9 categorías originales al verificarse que todas contaban con al menos 10 observaciones. El dataset final opera con 34 categorías creativas en total.

3.2. Feature Engineering

Transformación de la variable dependiente

El CTR en el dataset presenta una distribución marcadamente asimétrica hacia la derecha (skewness = 6,78), lo que viola el supuesto de homocedasticidad del modelo OLS y reduce la estabilidad de los estimadores. Se aplicó la transformación logarítmica $\log_ctr = \log(\text{CTR})$, que redujo la asimetría a 1,87, aproximando la distribución a una forma más simétrica y estabilizando la varianza. Los fundamentos estadísticos de esta decisión fueron desarrollados en la Sección 2.6.1.




Figura 3.1: Distribución del CTR original (izquierda) y de $\log(\text{CTR})$ (derecha). La transformación logarítmica reduce la asimetría de 6,78 a 1,87 y elimina la cola derecha extrema, haciendo la distribución más apta para el modelo OLS. El pico visible en $\log(\text{CTR}) \approx -4,6$ corresponde al valor mínimo reportado de $\text{CTR} = 0,01$ (*floor effect*).

Fuente: Elaboración propia en base a datos de TikTok Top Ads (Q1 2025).

Para el modelo OLS, la variable dependiente transformada fue adicionalmente estandarizada (z -score) de modo que los coeficientes resulten comparables en magnitud entre dimensiones y categorías con distintas escalas. De igual forma, la variable de control *duration* (duración del video en segundos) fue estandarizada antes de ingresar

al modelo. Las variables categóricas no requieren estandarización por estar codificadas como indicadoras.

Codificación de variables categóricas

El modelo OLS utiliza *sum-to-zero contrasts*, una codificación que distribuye los coeficientes de cada variable categórica alrededor del promedio global. Bajo este esquema, cada coeficiente expresa la desviación de esa categoría respecto a la gran media global, lo que permite comparar el rendimiento relativo de todas las categorías sin que los resultados dependan de la elección de una categoría de referencia arbitraria (Fox, 2016, Cap. 8).

Para el modelo Random Forest, en cambio, se utilizó codificación one-hot estándar con `drop_first=True`, que elimina una categoría por variable para evitar multicolinealidad perfecta. Esta elección es consistente con las convenciones de scikit-learn y no afecta la capacidad predictiva del modelo dado que los árboles de decisión son invariantes a la recodificación de las categorías de referencia.

Variables del modelo

Las variables predictoras se dividen en dos grupos. El primero lo conforman las tres dimensiones creativas objeto de análisis: *creative_theme* (9 categorías), *creative_concept* (8 categorías tras el colapso) y *talent_type* (8 categorías tras el colapso). El segundo grupo son las variables de control: *objective_value* (modalidad de optimización de la campaña, que distingue entre objetivos como Conversiones, Tráfico o Leads, entre otros), *campaign_objective* (objetivo general de la campaña) y *duration* (duración del video). Las variables de control permiten separar el efecto de los atributos creativos de las diferencias sistemáticas atribuibles al tipo de campaña o a características técnicas del anuncio (Cunningham, 2021, cap. 2).

3.3. Enfoque analítico

El enfoque analítico emplea dos modelos con roles distintos y complementarios, siguiendo la lógica propuesta por Mullainathan and Spiess (2017): explorar primero con aprendizaje automático para identificar qué variables importan, y estimar luego con econometría clásica para cuantificar cuánto y en qué dirección.

El primer paso utiliza un modelo Random Forest con valores SHAP para identificar qué dimensiones creativas tienen mayor importancia predictiva sobre el CTR. Sin asumir forma funcional entre predictores y respuesta, este modelo asigna a cada categoría

una contribución marginal promedio sobre todas las observaciones del corpus, lo que permite comparar dimensiones entre sí en la misma escala (Lundberg and Lee, 2017; Strobl et al., 2007).

El segundo paso utiliza un modelo OLS con contrastes de desviación (sum-to-zero) para cuantificar la dirección y magnitud de la asociación de cada categoría dentro de las dimensiones que el RF identificó como relevantes. Los coeficientes expresan la desviación de cada categoría respecto al promedio de su dimensión, en escala logarítmica. Para comunicarlos a equipos de estrategia creativa, se traducen como variación porcentual del CTR mediante la transformación $e^\beta - 1$.

La correlación de Spearman entre el ranking de importancia del RF y los coeficientes OLS ponderados por prevalencia ($\rho = 0,74$, $p < 0,001$) valida que ambos instrumentos capturan la misma señal empírica (Breiman, 2001b). Si RF identifica una categoría como relevante pero OLS no la confirma, puede indicar no linealidades que el modelo lineal no captura. Si OLS la señala pero RF no, es típico de categorías con efectos intensos pero poco frecuentes en el corpus.

3.3.1. Modelo de Mínimos Cuadrados Ordinarios (OLS)

El modelo OLS se especifica con la variable dependiente z_log_ctr (CTR en escala logarítmica y estandarizada) en función de las tres dimensiones creativas codificadas con contrastes sum-to-zero y las variables de control $z_duration$, $objective_value$ y $campaign_objective$:

$$z_log_ctr_i = \alpha + \sum_j \beta_j^{\text{theme}} \cdot \mathbf{1}[\text{theme}_i = j] + \sum_k \beta_k^{\text{concept}} \cdot \mathbf{1}[\text{concept}_i = k] + \sum_l \beta_l^{\text{talent}} \cdot \mathbf{1}[\text{talent}_i = l] + \gamma_1 \cdot z_duration_i + \boldsymbol{\delta}' \mathbf{w}_i + \varepsilon_i \quad (3.1)$$

donde $\mathbf{w}_i$ agrupa los indicadores de $objective_value$ y $campaign_objective$. Los errores estándar se estiman con el método HC1 de White (1980) para corregir por posible heterocedasticidad sin necesidad de suponer varianza constante de los residuos.

Diagnóstico de supuestos

El modelo in-sample arroja un R^2 de 0,595 y un R^2 ajustado de 0,562, lo que indica que las variables incluidas explican más de la mitad de la varianza del CTR logaritmizado dentro de la muestra. Para evaluar la capacidad predictiva fuera de muestra, se realizó una validación cruzada de 5 particiones (*5-fold cross-validation*), que

arrojó un R^2 out-of-sample promedio de $0,496 \pm 0,074$ (Breiman, 2001a). La estabilidad entre el R^2 in-sample y el CV indica ausencia de sobreajuste severo.

Respecto a los supuestos del modelo, el test de Shapiro-Wilk rechaza la normalidad de los residuos ($p < 0,05$). Sin embargo, la inspección visual del Q-Q plot y la distribución de residuos sugiere que la desviación no es severa: los residuos son aproximadamente simétricos y el Q-Q plot se ajusta razonablemente a la línea teórica salvo en los extremos. Con $n = 578$, el Teorema Central del Límite garantiza que la inferencia basada en errores estándar robustos HC1 es asintóticamente válida (Fox, 2016, cap. 5).




Figura 3.2: Gráficos de diagnóstico del modelo OLS. Superior derecha: Q-Q plot de residuos, con ajuste razonable a la línea teórica salvo en los extremos. Inferior izquierda: distribución de residuos aproximadamente simétrica. Ambos gráficos sugieren que la desviación de normalidad no compromete la inferencia.

Fuente: Elaboración propia.

La variable de control *objective_value* resulta la de mayor peso en el modelo: las campañas con objetivo de Conversiones muestran un coeficiente de $-1,16$ desviaciones estándar ($p < 0,001$), lo que refleja que los anuncios orientados a conversión tienden a tener CTR estructuralmente más bajo que los orientados a tráfico o reconocimiento de marca. Esta diferencia es esperable desde la lógica del embudo: las campañas de conversión suelen apuntar a audiencias más acotadas y con menor propensión al clic. La variable *duration* no resulta significativa ($p = 0,557$), lo que sugiere que la duración del video, dentro del rango observado en los Top Ads, no tiene un efecto lineal sistemático sobre el CTR.

3.3.2. Modelo Random Forest

El modelo de Random Forest se ajustó con la implementación `RandomForestRegressor` de `scikit-learn`. Los hiperparámetros utilizados fueron: `n_estimators=200` (número de árboles), `max_depth=10` (profundidad máxima por árbol), y

`random_state=42` (semilla para reproducibilidad).

La elección de 200 árboles garantiza la estabilización de las predicciones del ensamble sin incurrir en un costo computacional excesivo. El límite de profundidad de 10 niveles regula la complejidad de cada árbol individual, reduciendo el riesgo de sobreajuste respecto a árboles sin poda.

Las variables categóricas se codificaron con one-hot encoding estándar antes de ingresar al modelo. La variable dependiente es `log_ctr` (sin estandarizar, a diferencia del OLS), lo que no afecta el ranking de importancia de variables pero sí la escala de los valores SHAP.

El modelo presenta un R^2 in-sample de 0,897, notablemente más alto que el OLS, lo que es consistente con la capacidad del Random Forest de capturar relaciones no lineales e interacciones entre variables. Sin embargo, esta ganancia in-sample no se traduce en una mejora equivalente fuera de muestra: la validación cruzada de 5 pliegues arroja un R^2 promedio de $0,519 \pm 0,137$, solo marginalmente superior al 0,496 del OLS. Esta convergencia en el R^2 out-of-sample entre ambos modelos es una primera señal de robustez: la información predictiva presente en los datos es capturada de manera similar por un modelo lineal interpretable y por un ensamble no lineal de alta capacidad.




Figura 3.3: R^2 out-of-sample por fold en la validación cruzada de 5 folds para OLS y Random Forest. Las líneas punteadas indican los promedios (OLS: 0,496, RF: 0,519). La variabilidad entre folds es mayor en el RF, reflejo de su mayor sensibilidad a la composición de la muestra de training.

Fuente: Elaboración propia.

La importancia de variables se estima mediante valores SHAP (*SHapley Additive exPlanations*), calculados con el algoritmo TreeSHAP de [Lundberg and Lee \(2017\)](#), que aprovecha la estructura de árbol para una computación exacta y eficiente de los valores de Shapley. Para cada dimensión creativa, la importancia agregada se obtiene como el promedio del valor absoluto de los valores SHAP individuales de todas sus categorías

$(|\overline{\phi_j}|)$, ponderado implícitamente por la prevalencia de cada categoría en el dataset.

3.3.3. Análisis de robustez

El análisis de robustez evalúa en qué medida las conclusiones del modelo son sensibles a las decisiones metodológicas tomadas durante el proceso de feature engineering, en particular al criterio de colapso de categorías con baja cardinalidad.

Como se describió en la Sección 3.1, las categorías con $n < 10$ fueron colapsadas en una categoría residual “Other” para evitar estimadores inestables. Este procedimiento reduce el número de categorías operativas de 34 a un conjunto más conservador. La pregunta de robustez es si los rankings de importancia de las dimensiones creativas cambian sustancialmente al comparar el modelo original (34 categorías) con el modelo sobre el conjunto colapsado.

Los resultados indican que los modelos son estables ante este cambio. El R^2 out-of-sample del OLS se mantiene en $0,496 \pm 0,074$ y el del Random Forest en $0,519 \pm 0,137$ en ambas especificaciones. Más relevante aún, la correlación de Spearman entre los coeficientes OLS (ponderados por prevalencia de categoría) y los valores SHAP del Random Forest se mantiene alta y significativa ($\rho = 0,736$, $p < 0,001$) en el modelo original, confirmando que la concordancia entre enfoques no es un artefacto de las categorías de alta cardinalidad sino una propiedad robusta del dataset.

Esta estabilidad implica que las conclusiones sobre qué dimensiones creativas están más fuertemente asociadas con el CTR no dependen críticamente de cómo se traten las observaciones poco frecuentes, lo que fortalece la validez interna del análisis.

Un segundo análisis evalúa si los rankings de importancia de las dimensiones creativas dependen de la inclusión de *objective_value* y *duration* como variables de control. Para ello, se entrenó un Random Forest adicional utilizando exclusivamente las tres dimensiones creativas, sin ninguna variable de control. La caída en capacidad predictiva es marcada: el R^2 fuera de muestra desciende de $0,519 \pm 0,137$ en el modelo completo a $-0,043 \pm 0,074$ en el modelo reducido. Este resultado es esperable: las campañas configuradas con objetivo de conversión exhiben CTRs estructuralmente más bajos que otras configuraciones con independencia de cualquier decisión creativa, y omitir esa diferencia introduce un ruido sistemático que el modelo no puede compensar. La magnitud del colapso en R^2 confirma, más que cuestiona, la decisión de incluir ambos controles: son indispensables para aislar la asociación creativa del efecto de configuración de campaña.

La pregunta central es si la señal creativa sobrevive a la ausencia de los controles. Para evaluarlo, se calculó la correlación de Spearman entre los valores SHAP promedio por categoría producidos por el modelo completo y los producidos por el modelo sin

controles. La correlación resultante es $\rho = 0,753$ ($p < 0,001$, $n = 39$ categorías), lo que indica una alta estabilidad estructural del ranking: las mismas categorías creativas tienden a ocupar posiciones similares con independencia de la especificación del modelo. Los controles son necesarios para la correcta identificación estadística, pero la asociación entre dimensiones creativas y CTR es una propiedad del dataset que emerge con o sin ellos.

3.4. Limitaciones del estudio

El análisis presentado en este trabajo tiene un carácter descriptivo y predictivo: su objetivo es identificar qué dimensiones creativas están *asociadas* con mayor CTR en el dataset disponible, sin pretender establecer relaciones causales. Las siguientes limitaciones son inherentes al diseño del estudio y deben tenerse en cuenta al interpretar los resultados.

Normalidad de los residuos y efecto piso del CTR. El test de Shapiro–Wilk rechaza la normalidad de los residuos del modelo OLS ($p < 0,05$). Sin embargo, este resultado no invalida el análisis por dos razones. Primero, con $n = 578$, el Teorema Central del Límite asegura que la distribución muestral de los coeficientes es aproximadamente normal, por lo que la inferencia basada en errores estándar robustos HC1 (White, 1980) es asintóticamente válida (Fox, 2016, Cap. 5). Segundo, el patrón estructural observado en los gráficos de diagnóstico es consistente con la naturaleza discreta del CTR en el dataset: el valor mínimo reportado es 0,01, lo que genera una masa de probabilidad concentrada en $\log(\text{CTR}) = -4,6$ (*floor effect*), produciendo artificialmente las bandas visibles en los residuos. Este patrón no es heterocedasticidad clásica sino un artefacto de la discretización de la variable dependiente.

Posible autocorrelación en los residuos. El estadístico de Durbin–Watson arroja un valor de aproximadamente 0,76, bastante por debajo del rango libre de autocorrelación. Este resultado es consistente con la presencia de agrupamiento intra-marca (*clustering*): el dataset contiene múltiples anuncios de los mismos anunciantes, y los anuncios de una misma marca comparten características no observadas (identidad visual, tono comunicacional, presupuesto) que los hacen más similares entre sí que a los anuncios de otras marcas. Esto viola el supuesto de independencia de las observaciones (Breiman, 2001b). En ausencia de identificadores de anunciante en el dataset, no es posible aplicar errores estándar agrupados (*clustered SE*), y la autocorrelación se reporta como limitación y sus implicaciones deben considerarse al evaluar la precisión

de los errores estándar reportados.

Sesgos en la medición de importancia de variables. La importancia por impureza de Gini tiene sesgo hacia variables con mayor cardinalidad (Strobl et al., 2007). Por este motivo se emplean valores SHAP como métrica primaria de importancia. Sin embargo, la importancia condicional (Strobl et al., 2008) no se implementa en este análisis: dado que `creative_theme` y `creative_concept` pueden estar correlacionadas, la importancia por permutación y SHAP podrían sobreestimar la contribución de una de ellas al capturar varianza compartida. Este punto constituye una limitación reconocida que podría abordarse en investigación futura.

Sesgo de selección y representatividad del dataset. Los datos provienen de TikTok Top Ads, una plataforma curada que exhibe los anuncios con mejor desempeño histórico. Esto introduce un sesgo de supervivencia: los anuncios de baja performance están sub-representados en el dataset, lo que implica que los coeficientes estimados reflejan patrones dentro del subconjunto de anuncios exitosos y no necesariamente serían replicables sobre el universo completo de anuncios publicados. Las asociaciones reportadas son válidas como descripción de los anuncios de alto rendimiento, pero deben interpretarse con cautela como guía prescriptiva universal.

4. Resultados

4.1. Análisis Exploratorio de los Datos

El dataset comprende 578 avisos publicitarios extraídos de TikTok Top Ads correspondientes al primer trimestre de 2025. Cada observación representa una campaña única codificada en las tres dimensiones creativas del modelo: *creative_theme* (9 categorías), *creative_concept* (20 categorías) y *talent_type* (8 categorías incluyendo “No Talent”). Las variables de control *objective_value* (3 categorías: App Installs, Conversions, Product Sales) y *campaign_objective* (7 categorías) completan la especificación.

La variable dependiente, CTR, presenta una distribución fuertemente sesgada a la derecha: la media es 0.034, la mediana 0.010, y el valor máximo observado es 0.94. Esta asimetría es consistente con la literatura sobre métricas de performance digital, donde la gran mayoría de los avisos obtiene rendimientos modestos y unos pocos concentran valores extremos. La Figura 3.1 (presentada en la sección de metodología) muestra la distribución original junto con su transformación logarítmica, considerablemente más simétrica (media = -4.09 , desvío estándar = 0.93), que es la que se utiliza como variable dependiente en todos los modelos.

En cuanto a la composición de la muestra, la categoría más frecuente de *creative_concept* es “Product demo” ($n = 252$, 43.6 % del total), seguida por “Not Applicable” ($n = 100$, 17.3 %). Para *creative_theme*, la categoría dominante es “Product-Centric” ($n = 220$, 38.1 %). En *talent_type*, “No Talent” es la más representada ($n = 227$, 39.3 %), seguida de “Customers” ($n = 120$, 20.8 %). Esta concentración en pocas categorías es esperable en datos de plataformas publicitarias y tiene implicancias para la estimación de coeficientes en las categorías minoritarias, que se discuten más adelante.

4.2. Análisis Univariado

Como primer paso descriptivo, se calculó el CTR medio por categoría para cada dimensión creativa. Este análisis no controla por ninguna otra variable y, por tanto, sus resultados deben interpretarse con cautela: las diferencias observadas pueden reflejar tanto el efecto de la dimensión creativa como la composición de los objetivos de campaña u otras variables no observadas. Su valor es fundamentalmente orientativo para identificar patrones que luego se validan con el análisis multivariado.




Figura 4.1: CTR medio por categoría para las tres dimensiones creativas analizadas. Las barras representan el CTR promedio por grupo. El tamaño de muestra por categoría varía considerablemente.

4.2.1. Creative Theme

Para *creative_theme* (Figura 4.1, panel superior), “Product-Centric” ($n = 220$, CTR = 0.045) y “Testimonial & Social Proof” ($n = 37$, CTR = 0.039) presentan los valores más altos, mientras que “Humor & Entertainment” ($n = 32$, CTR = 0.015) y “Trend-Based & Reactive” ($n = 10$, CTR = 0.011) se ubican en el extremo inferior. Llama la atención que el humor (contenido nativo y culturalmente central en TikTok) esté asociado con CTR relativamente bajo incluso en el análisis descriptivo, anticipando uno de los hallazgos más robustos del modelo multivariado.

4.2.2. Creative Concept

Para *creative_concept* (panel central), “Event-driven” ($n = 3$, CTR = 0.347) encabeza el ranking, pero con apenas tres observaciones su estimación es muy inestable. Con mayor representación estadística, “Day-in-the-life story” ($n = 36$, CTR = 0.048) y “Product demo” ($n = 252$, CTR = 0.040) presentan los valores más sólidos. En el extremo inferior, categorías como “Meme-based content”, “FAQ” y “Flash sale” reportan el CTR mínimo del dataset (0.010).

4.2.3. Talent Type

Para *talent_type* (panel inferior), los avisos protagonizados por influencers ($n = 56$, CTR = 0.064) y actores ($n = 47$, CTR = 0.047) lideran el ranking descriptivo. Sin embargo, como se verá en el análisis multivariado, esta ventaja desaparece al controlar por el tipo de objetivo de campaña, lo que sugiere que los influencers se utilizan predominantemente en campañas de App Installs o Product Sales, que por diseño generan CTR más elevado independientemente del contenido creativo.

4.3. Análisis Multivariado

4.3.1. Mínimos Cuadrados Ordinarios (OLS)

El modelo OLS estima la asociación entre las dimensiones creativas y $\log(\text{CTR})$, controlando simultáneamente por *objective_value*, *campaign_objective* y *duration*. Se utilizan errores estándar robustos HC1 (White, 1980) para corregir potencial heterocedasticidad. El R^2 in-sample es 0.595 (ajustado: 0.562). La validación cruzada de 5 particiones arroja un R^2 promedio de 0.496 ± 0.07 , lo que indica que el modelo generaliza de forma razonable fuera de la muestra de entrenamiento.

La Tabla 4.1 presenta los coeficientes para las variables creativas. Los controles de campaña se incluyen en la especificación pero se reportan completos en la Tabla A.2 del Anexo.

Cuadro 4.1: Coeficientes OLS estadísticamente significativos ($p < 0,05$). Variable dependiente: $\log(\text{CTR})$. Errores estándar HC1.

Variable	Coef.	SE	t	p
<i>Creative Theme</i>				
Humor & Entertainment	-0.470***	0.142	-3.32	0.001
Product-Centric	+0.240*	0.097	+2.48	0.013
Testimonial & Social Proof	+0.315**	0.108	+2.90	0.004
<i>Creative Concept</i>				
Aspirational creator collaboration	+0.605***	0.142	+4.25	0.000
Day-in-the-life story	+0.404**	0.137	+2.95	0.003
Event-driven	+1.256**	0.428	+2.94	0.003
FAQ	-0.387**	0.136	-2.84	0.004
Meme-based content	-0.561**	0.212	-2.64	0.008
<i>Talent Type</i>				
Customers	-0.130*	0.061	-2.12	0.034
No Talent	-0.134*	0.053	-2.52	0.012
<i>Controles de campaña</i>				
<i>objective_value</i> , <i>campaign_objective</i> , <i>duration</i>	incluidos (ver Tabla A.2 en Anexo)			
R^2 (in-sample)	0.595			
R^2 ajustado	0.562			
R^2 (validación cruzada 5-fold)	0,496 $\pm$ 0,07			
n	578			

Nota: * $p < 0,05$, ** $p < 0,01$, *** $p < 0,001$. Variables no significativas omitidas; ver tabla completa en Anexo.

Entre las variables creativas significativas al 5% se identifican patrones claros en las tres dimensiones. En *creative_theme*, “Humor & Entertainment” está asociado con un CTR significativamente más bajo ($\beta = -0,470$, $p < 0,001$), mientras que “Product-Centric” ($\beta = +0,240$, $p = 0,013$) y “Testimonial & Social Proof” ($\beta = +0,315$, $p = 0,004$) se asocian con mayor CTR. En *creative_concept*, “Day-in-the-life story” ($\beta = +0,404$, $p = 0,003$) y “Aspirational creator collaboration” ($\beta = +0,605$, $p < 0,001$) muestran las asociaciones positivas más robustas, aunque esta última cuenta con apenas dos observaciones en la muestra, lo que limita la confiabilidad de su esti-

mación. Del lado negativo, “Meme-based content” ($\beta = -0,561$, $p = 0,008$) y “FAQ” ($\beta = -0,387$, $p = 0,004$) presentan coeficientes significativos. En *talent_type*, tanto “Customers” ($\beta = -0,130$, $p = 0,034$) como “No Talent” ($\beta = -0,134$, $p = 0,012$) están asociados negativamente con el CTR. Llamativamente, “Influencers” no alcanza significancia estadística ($p = 0,296$) una vez que se controla por el objetivo de campaña.



Figura 4.2: Coeficientes OLS con intervalos de confianza al 95 % para las variables creativas. Los puntos a la derecha de la línea cero indican asociación positiva con $\log(\text{CTR})$. Los de la izquierda indican asociación negativa.

La Figura 4.2 resume visualmente los coeficientes con sus intervalos de confianza. Vale la pena destacar el rol de *objective_value*: la categoría “Conversions” tiene el coefi-

ciente negativo más alto de todo el modelo, lo que es esperable dado que las campañas optimizadas por conversiones instruyen al algoritmo de TikTok a mostrar el aviso a audiencias más selectivas con alta probabilidad de completar una acción, reduciendo estructuralmente el CTR (Yang et al., 2025). Esta dominancia valida que el modelo captura señal real sobre cómo el algoritmo de distribución afecta las métricas observadas, y refuerza la necesidad de controlar por este factor para aislar la contribución creativa.

4.3.2. Random Forest y análisis SHAP

El modelo Random Forest, ajustado con 200 árboles y profundidad máxima de 10, alcanza un R^2 en validación cruzada de $0,519 \pm 0,14$, comparable al OLS ($0,496 \pm 0,07$), tal como se discutió en la sección de metodología. El foco de esta sección es la interpretación de las variables creativas a través del análisis SHAP.

Para interpretar la contribución de cada variable al Random Forest se utilizan valores SHAP (Lundberg and Lee, 2017), que miden el cambio promedio en la predicción atribuible a cada variable en cada observación individual. La Figura 4.3 presenta el *beeswarm plot* con las 20 variables de mayor importancia SHAP.




Figura 4.3: SHAP *beeswarm plot*: las 20 variables con mayor importancia promedio $|\text{SHAP}|$. Cada punto representa una observación. El color indica el valor de la variable (rojo = alto, azul = bajo). La posición horizontal indica el impacto en la predicción del modelo.

El análisis SHAP confirma que *objective_value_Conversions* es la variable con mayor importancia en todo el modelo. Al concentrarse en las variables creativas, la Figura 4.4 muestra que, a nivel de dimensión agregada, *creative_theme* acumula el mayor $|\text{SHAP}|$ promedio, seguida por *talent_type* y *creative_concept*. Este ranking coincide con el obtenido por OLS en términos de la magnitud de los coeficientes significativos.




Figura 4.4: Importancia SHAP media ($|\text{SHAP}|$) agregada por dimensión creativa. Las barras representan la contribución promedio de cada dimensión a las predicciones del modelo Random Forest.

4.3.3. Convergencia entre modelos

Esta sección contrasta el ranking de importancia del RF con los coeficientes del OLS para verificar que ambos instrumentos capturan la misma señal, y para presentar la dirección y magnitud de las categorías más relevantes en términos accionables. Para hacer la comparación en la misma escala, es necesario considerar que sus métricas son distintas: el coeficiente OLS mide el efecto puro de una categoría respecto al promedio de su dimensión, mientras que el $|\text{SHAP}|$ promedio refleja ese efecto ponderado por la frecuencia de aparición de la categoría en el dataset. Una categoría con $n = 2$ observaciones puede tener un coeficiente OLS muy alto pero un SHAP cercano a cero, simplemente porque afecta a muy pocas observaciones.

Para resolver esta diferencia de escala, se pondera el coeficiente OLS por la prevalencia de cada categoría ($n_{\text{cat}}/578$) antes de calcular la correlación. La correlación de Spearman entre el OLS ponderado y el $|\text{SHAP}|$ promedio, calculada sobre las 34 categorías con representación individual, es $\rho = 0,74$ ($p < 0,001$), confirmando que el ranking de importancia del RF y los coeficientes del OLS apuntan en la misma dirección (Breiman, 2001b).




Figura 4.5: Convergencia entre OLS (coeficiente ponderado por prevalencia) y SHAP ($|\text{SHAP}|$ promedio) a nivel de categoría individual ($n = 34$). La correlación de Spearman es $\rho = 0,74$ ($p < 0,001$).

La Tabla 4.2 resume las categorías a partir de ese contraste. El criterio de clasificación combina posición en el ranking SHAP (top 10) y significancia estadística en OLS: el **Top Tier** agrupa las categorías que el RF identifica entre las más importantes *y* para las cuales OLS estima coeficientes estadísticamente significativos al 5 %, aportando dirección e interpretación cuantificable. El Tier 2 incluye categorías con alto SHAP pero sin significancia OLS, lo que puede indicar asociaciones no lineales que el modelo lineal no captura. El Tier 3 contiene categorías con OLS significativo pero SHAP bajo, patrón típico de categorías con efectos individuales intensos pero poca frecuencia en el corpus.

Cuadro 4.2: Clasificación de categorías creativas por convergencia entre modelos

Dir.	Categoría	Dimensión	n	CTR medio	OLS coef.	SHAP rank
Top Tier: ambos modelos coinciden						
–	Humor & Entertainment	creative_theme	32	0.015	–0,470***	#1
–	No Talent	talent_type	227	0.029	–0,134*	#2
+	Day-in-the-life story	creative_concept	36	0.048	+0,404**	#3
–	Customers	talent_type	120	0.025	–0,130*	#4
+	Product-Centric	creative_theme	220	0.045	+0,240*	#8
Tier 2: alto SHAP, OLS no significativo						
+	Lifestyle & Aspirational	creative_theme	49	0.031	+0,028	#6
–	Not Applicable (sin concepto)	creative_concept	100	0.031	–0,079	#7
+	Promotional & Offer-Based	creative_theme	128	0.033	+0,144	#9
+	Comb. actores y clientes	talent_type	25	0.029	+0,152	#10
Tier 3: OLS significativo, SHAP bajo (efecto intenso, pocos casos)						
+	Event-driven	creative_concept	3	0.347	+1,256**	#14
–	Meme-based content	creative_concept	6	0.010	–0,561**	#26
–	FAQ	creative_concept	14	0.015	–0,387**	#23
+	Testimonial & Social Proof	creative_theme	37	0.039	+0,315**	#19

Nota: * $p < 0,05$, ** $p < 0,01$, *** $p < 0,001$. SHAP rank = posición en el ranking de |SHAP| promedio sobre las 34 categorías individuales. “Dir.” indica la dirección de la asociación con $\log(\text{CTR})$.

El hallazgo más contraintuitivo del análisis es la posición de “Humor & Entertainment” como el predictor creativo de mayor importancia SHAP, con asociación negativa. En una plataforma cuyo contenido orgánico está dominado por el entretenimiento, la hipótesis más probable es que el humor funcione bien para métricas de engagement (likes, compartidos) pero no necesariamente para generar clics con intención de compra. Esta interpretación es consistente con el marco de [Lang \(2000\)](#) sobre la capacidad limitada de procesamiento del mensaje: los avisos humorísticos capturan atención pero pueden no activar la intención de acción directa que el CTR mide. A su vez, la dominancia de “No Talent” (avisos sin presencia humana, $n = 227$) como segundo predictor en SHAP sugiere que la estrategia de mostrar únicamente el producto no está asociada con mayores tasas de clic en el ecosistema TikTok, donde la presencia de personas (especialmente en formatos auténticos como *day-in-the-life*) parece jugar un rol relevante.

5. Conclusión

5.1. Alineación con la teoría de Direct Response

Los resultados de este trabajo son coherentes con los principios fundamentales del *direct response*, la tradición publicitaria que subordina la decisión creativa al estímulo de una acción medible e inmediata por parte del usuario. En ese paradigma, la pieza creativa no tiene como fin primario construir imagen de marca ni generar resonancia emocional difusa, sino provocar un comportamiento concreto (el clic, la descarga, la compra) en el menor tiempo posible. Los hallazgos del análisis se alinean con esta lógica de dos maneras complementarias.

Por un lado, las variables de control confirman que el tipo de optimización de campaña estructura el CTR de manera determinante: los anuncios configurados para Conversiones presentan un coeficiente negativo fuerte ($-0,257^{***}$) en relación con el resto, no porque esas campañas funcionen peor, sino porque el algoritmo de TikTok las sirve a audiencias más pequeñas y selectivas con alta propensión a convertir. Controlar por esta variable permite aislar el efecto de las decisiones creativas puras.

Por otro lado, las categorías creativas con mayor capacidad predictiva positiva (como *Product-Centric* en tema creativo, y *Day-in-the-life story* en concepto) son precisamente aquellas que mantienen el producto o la propuesta de valor en el centro del relato. Esto contrasta con categorías narrativamente más elaboradas (como *Humor & Entertainment*) que, si bien son populares en el contenido orgánico de TikTok, resultan asociadas negativamente con el CTR en el contexto de publicidad paga. La interpretación más parsimoniosa es que el humor y el entretenimiento retienen la atención pero no necesariamente direccionan hacia la acción, lo que genera un clic inferior al que predicen las impresiones conseguidas. En un modelo de *performance* donde cada impresión tiene un costo, esa brecha importa.

En conjunto, estos resultados sugieren que, dentro del ecosistema de TikTok, las creatividades más eficientes en términos de CTR son las que combinan la estética nativa de la plataforma (video corto, ritmo rápido, textura de contenido orgánico) con una señal de respuesta directa inequívoca: un producto visible, una propuesta concreta, un llamado a la acción explícito.

5.2. Implicancias para equipos creativos y de medios

La contribución más importante de este trabajo no radica en los coeficientes específicos estimados para el período analizado, sino en la metodología que los produce. Las asociaciones observadas entre dimensiones creativas y CTR son válidas para la muestra de TikTok Top Ads del primer trimestre de 2025. Las redes sociales, y TikTok en particular, evolucionan a un ritmo que hace que cualquier ranking de categorías tenga una vida útil acotada: los formatos que hoy son nativos mañana son predecibles, y los algoritmos de distribución se reajustan constantemente en función del comportamiento de los usuarios.

Lo que sí permanece es el *pipeline* analítico propuesto: etiquetar el portfolio creativo con las dimensiones del CDS, vincular esas etiquetas con métricas de performance, y correr OLS más Random Forest con SHAP para identificar qué categorías están más asociadas con resultados superiores. Ese ciclo puede (y debería) repetirse periódicamente, idealmente con cada actualización relevante del dataset. El valor entregado al equipo creativo no es una lista estática de qué hacer y qué evitar, sino una herramienta de diagnóstico que se actualiza a medida que cambia el entorno competitivo.

Dicho esto, los resultados actuales sí ofrecen señales accionables para el corto plazo. Las implicancias se pueden organizar en tres niveles:

Nivel de tema creativo (*creative_theme*): *Product-Centric* está asociado positivamente con el CTR (+0,241**), lo que sugiere que mantener el producto como protagonista visual y narrativo del anuncio favorece la respuesta directa. Por el contrario, *Humor & Entertainment* presenta la asociación negativa más fuerte en esta dimensión (−0,470***). Para equipos que producen contenido de entretenimiento en TikTok, este resultado es un llamado de atención: lo que funciona orgánicamente no necesariamente traciona en el contexto pago.

Nivel de concepto creativo (*creative_concept*): *Day-in-the-life story* aparece como el concepto más consistentemente asociado con CTR elevado (+0,404**), y converge entre OLS y Random Forest. Conceptos como *Meme-based content* y *FAQ* presentan asociaciones negativas en ambos modelos. *Event-driven* (+1,256**) muestra un coeficiente muy alto pero con pocas observaciones (n=3), por lo que debe interpretarse con cautela.

Nivel de talento (*talent_type*): la presencia de talento en el anuncio, independientemente del tipo, está asociada con CTR superior al de los anuncios sin presencia humana (*No Talent*: −0,134*). En particular, los anuncios que recurren exclusivamente a clientes como presentadores (*Customers*: −0,130*) muestran también una asociación

negativa. Esto sugiere que, en el contexto de *performance*, el talento con mayor credibilidad técnica o aspiracional (influencers, actores) está más ligado al clic que el UGC puro.

La recomendación operativa central es incorporar este análisis como parte del flujo de trabajo habitual del equipo creativo, con una frecuencia alineada a la cadencia de renovación del portfolio de anuncios. No como una receta fija, sino como un espejo que permite contrastar las apuestas creativas actuales contra lo que la evidencia más reciente indica que funciona en la plataforma.

5.3. Análisis multivariado versus univariado

El análisis exploratorio univariado presentado en la Sección 4.1 (distribuciones de CTR por categoría) ofrece una primera aproximación intuitiva a los datos, pero resulta insuficiente como base para recomendaciones creativas. La razón es que el CTR medio de una categoría observado en el dataset no es el efecto de esa categoría: está contaminado por la composición de las campañas que la contienen.

El ejemplo más claro es *objective_value*: la dimensión con mayor capacidad predictiva en todo el modelo no es una decisión creativa sino una configuración de plataforma (el tipo de optimización de campaña). Si no se controla por esta variable, el CTR crudo de una categoría creativa refleja en parte el mix de objetivos de campaña de los anuncios que la componen, no su mérito creativo intrínseco. Un anuncio de *Day-in-the-life* que corra con objetivo Conversiones tendrá, en promedio, un CTR menor que el mismo concepto corriendo con objetivo App Installs. Sin el control multivariado, esa diferencia se atribuye erróneamente al concepto.

El análisis OLS resuelve este problema al estimar el coeficiente de cada categoría manteniendo constantes el resto de las dimensiones y los controles. La validación cruzada con Random Forest y SHAP agrega una capa adicional: al no asumir ninguna forma funcional, el modelo algorítmico confirma de manera independiente qué dimensiones concentran más poder predictivo. La convergencia entre ambos modelos (Spearman $\rho = 0,74$, $p < 0,001$ al comparar a nivel de categoría individual con métrica ponderada) es precisamente el argumento más sólido del trabajo: cuando dos enfoques radicalmente distintos señalan las mismas categorías como relevantes, la señal es robusta independientemente de los supuestos específicos de cada modelo ([Breiman, 2001b](#)).

5.4. Limitaciones del estudio

Los resultados de este trabajo deben interpretarse con las siguientes limitaciones en mente.

Diseño observacional y alcance correlacional. El dataset proviene de TikTok Top Ads, una fuente observacional sin asignación aleatoria de tratamientos. Las asociaciones estimadas no tienen interpretación causal: no es posible afirmar que usar *Product-Centric causa* un CTR más alto, sino únicamente que, en este corpus y período, los anuncios con esa categoría estuvieron asociados con CTR superior, controlando por el resto de las variables del modelo. La ausencia de un diseño experimental impide aislar el efecto de cada decisión creativa de las demás características no observadas del anuncio o del anunciante.

Sesgo de selección en el corpus. TikTok Top Ads es un subconjunto de anuncios de alta performance. Los anuncios con CTR muy bajo probablemente estén subrepresentados, lo que implica que los coeficientes estimados capturan asociaciones dentro de la distribución alta del CTR, no necesariamente en el universo completo de publicidad en TikTok. Esto acota la generalización de los resultados a portafolios creativos ya razonablemente eficientes.

Normalidad de residuos. El test de Shapiro-Wilk rechaza la normalidad de los residuos ($p < 0,05$). Sin embargo, este resultado no invalida el análisis por dos razones. Primero, con $n = 578$, el Teorema Central del Límite asegura que la distribución muestral de los coeficientes es aproximadamente normal, por lo que la inferencia basada en errores estándar robustos HC1 es asintóticamente válida (Fox, 2016). Segundo, el patrón estructural observado en los gráficos de diagnóstico es consistente con la naturaleza discreta del CTR en el dataset: el valor mínimo reportado es 0,01, lo que genera una masa de probabilidad concentrada en $\log(\text{CTR}) = -4,6$ (efecto piso), produciendo las bandas visibles en los residuos. Se reporta como limitación junto con la baja continuidad de la variable dependiente.

Posible autocorrelación intra-marca. El estadístico Durbin-Watson ($\approx 0,76$) sugiere la posible presencia de dependencia en los residuos, atribuible a que varias observaciones del dataset corresponden a campañas del mismo anunciante. Anuncios del mismo portafolio comparten características no observadas (tono de marca, audiencia histórica, nivel de madurez de la cuenta), lo que puede generar correlación intra-grupo que el OLS estándar no modela. Si bien los errores robustos HC1 mitigan parcialmente este efecto, una especificación con efectos fijos de anunciante o errores clusterizados por marca sería metodológicamente más rigurosa y se señala como extensión directa del trabajo.

Dimensiones CDS excluidas del análisis. El CDS contempla seis dimensiones operativas, pero tres de ellas no exhiben varianza en este corpus: el formato de producción es exclusivamente video corto (plataforma homogénea), el canal es 100 % TikTok, y la rotación o renovación de anuncios no es medible en un corte transversal. Estas exclusiones no son una limitación del diseño sino una consecuencia de la naturaleza del dataset y se justifican metodológicamente: solo es posible modelar lo que varía. Las tres dimensiones restantes (*creative_theme*, *creative_concept*, *talent_type*) proveen suficiente variabilidad para el análisis.

5.5. Relación con el marco de Creative Diversity Score (CDS)

Uno de los aportes metodológicos de este trabajo consiste en demostrar que las dimensiones del CDS son operacionalizables y medibles empíricamente mediante técnicas estadísticas estándar. Esto es relevante porque el CDS fue concebido originalmente como una herramienta de diagnóstico cualitativo y auditoría interna (Ready Set, 2025). Al vincular sus dimensiones con una variable de performance cuantitativa como el CTR, este análisis da un paso hacia la validación empírica del framework.

El resultado más importante en este sentido no es cuál categoría específica tiene mayor CTR asociado, sino que las tres dimensiones con varianza en el dataset (*creative_theme*, *creative_concept*, *talent_type*) explican en conjunto una fracción relevante de la varianza del CTR ($R^2_{CV} = 0,496 \pm 0,07$) incluso después de controlar por el tipo de campaña. Esto indica que las categorías del CDS capturan variación genuina en la performance del anuncio, no solo diferencias en la configuración de la campaña.

Al mismo tiempo, la heterogeneidad dentro de cada dimensión es importante. No es que “más *creative_theme*” se asocie linealmente con más CTR: algunas categorías de esa dimensión tienen coeficientes positivos significativos y otras negativos significativos. Esto refuerza la idea de que el CDS es útil no solo como índice de diversidad agregado, sino como mapa granular que distingue qué tipos de variación aportan y cuáles no. En ese sentido, el análisis propuesto en este trabajo puede integrarse al flujo de trabajo del CDS como una etapa de calibración empírica: periódicamente, vincular las etiquetas CDS del portfolio con los datos de performance disponibles para identificar qué categorías, en el contexto específico del cliente y del momento del mercado, están realmente correlacionadas con resultados superiores.

5.6. Líneas futuras de investigación

La extensión más directa e inmediata de este trabajo es su replicación longitudinal. El análisis aquí presentado constituye un corte transversal correspondiente al primer trimestre de 2025. Repetir el mismo pipeline analítico sobre datasets de períodos sucesivos (trimestre a trimestre, o con una cadencia alineada a la renovación del portfolio creativo de cada cliente) permitiría dos avances complementarios: por un lado, evaluar la estabilidad temporal de las asociaciones identificadas y detectar cuándo el ranking de categorías cambia de manera significativa. Por otro lado, convertir el pipeline en una herramienta de monitoreo continuo en lugar de un análisis de una sola corrida. La naturaleza dinámica de TikTok hace de esta extensión no solo una posibilidad teórica sino una necesidad práctica para cualquier equipo de performance que quiera mantener sus recomendaciones creativas actualizadas.

Una segunda línea relevante es la extensión del análisis a otras plataformas de paid social (Meta, YouTube Shorts, Pinterest). Muchas de las dimensiones del CDS son agnósticas respecto de la plataforma, lo que permitiría testear en qué medida las asociaciones observadas en TikTok se replican en entornos con algoritmos y audiencias distintos. La convergencia entre plataformas reforzaría considerablemente la solidez externa de los hallazgos. La divergencia, por su parte, sería igualmente informativa sobre qué aspectos de la performance creativa son específicos del ecosistema TikTok.

Una tercera línea concierne a la inferencia causal. El diseño observacional de este trabajo impide atribuir causalidad a los coeficientes estimados. Para superar esa limitación, sería necesario un diseño experimental controlado: asignar aleatoriamente variantes creativas a conjuntos de audiencias equivalentes y medir el CTR diferencial. En el contexto de paid social, esto es operacionalmente factible mediante tests A/B corridos directamente en la plataforma, siempre que se disponga de control suficiente sobre la configuración de la campaña para aislar la variable creativa.

Una cuarta línea es la incorporación de variables creativas adicionales disponibles en el dataset pero excluidas del análisis principal. La variable *is_ugc* (presencia de contenido generado por usuarios) muestra diferencias descriptivas importantes entre grupos (CTR medio de 0,038 para UGC versus 0,017 para no-UGC). La dimensión *demographic_representation* tiene potencial analítico, aunque requiere colapso de categorías de baja frecuencia. Incorporar estas variables en un modelo ampliado, con la misma estrategia de validación cruzada y contraste con Random Forest, podría enriquecer el mapa de asociaciones creativas sin comprometer la robustez metodológica.

Finalmente, una limitación estructural de este trabajo (la dependencia de una fuente pública de alto desempeño) podría superarse mediante acuerdos de colaboración con

anunciantes o agencias que dispongan de datos de performance propios, incluyendo anuncios de performance media y baja. Un dataset con mayor heterogeneidad en la variable dependiente permitiría estimar las asociaciones con mayor precisión estadística y con menor sesgo de selección, ampliando la validez externa de los resultados.

Bibliografía

- Ad-Lib.io (2022). Creative fatigue in always-on campaigns. Ad-Lib.io Blog.
- Backlinko (2025). TikTok user statistics 2025. Backlinko Research. <https://backlinko.com/tiktok-users>.
- Breiman, L. (2001a). Random forests. *Machine Learning*, 45(1):5–32.
- Breiman, L. (2001b). Statistical modeling: The two cultures. *Statistical Science*, 16(3):199–231.
- Cunningham, S. (2021). *Causal Inference: The Mixtape*. Yale University Press, New Haven, CT. Versión online gratuita: <https://mixtape.scunning.com/>.
- Digital Silk (2025). Social media advertising statistics 2025. Digital Silk Research.
- eMarketer (2024). Us social media ad spending forecast 2024–2027. eMarketer Report.
- eMarketer (2025). Us TikTok daily time spent 2025. eMarketer Report.
- Facebook IQ (2016). Capturing attention in feed: The science behind effective video creative. Facebook for Business — Insights. <https://www.facebook.com/business/news/insights/capturing-attention-feed-video-creative>.
- Ferrari, S. L. P. and Cribari-Neto, F. (2004). Beta regression for modelling rates and proportions. *Journal of Applied Statistics*, 31(7):799–815. PDF gratuito: <https://www.ime.usp.br/~sferrari/beta.pdf>.
- Fox, J. (2016). *Applied Regression Analysis and Generalized Linear Models*. SAGE Publications, Thousand Oaks, CA, 3 edition.
- Hastie, T., Tibshirani, R., and Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, New York, 2 edition. Disponible en: <https://hastie.su.domains/ElemStatLearn/>.
- Kantar Media (2023). Creative effectiveness: KFC case study. Kantar Media Whitepaper.
- Khan, U., Kim, S., Choi, S., and Labroo, A. (2025). Diversity representations in advertising: Enhancing variety perceptions and brand outcomes. *Journal of Consumer Research*, 52(1):179–204.

- Lang, A. (2000). The limited capacity model of mediated message processing. *Journal of Communication*, 50(1):46–70.
- Lundberg, S. M. and Lee, S.-I. (2017). A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30, pages 4765–4774. arXiv: <https://arxiv.org/abs/1705.07874>.
- Meng, L. M., Kou, S., Duan, S., and Bie, Y. (2024). The impact of content characteristics of short-form video ads on consumer purchase behavior: Evidence from TikTok. *Journal of Business Research*, 183:114874.
- Meta for Business (2024a). Creative diversity: How multiple ads lower CPA. Meta for Business Blog. <https://www.facebook.com/business/>.
- Meta for Business (2024b). Visual differentiation and CPA reduction. Meta for Business Blog.
- Meta Platforms (2025). Quarterly earnings report Q2 2025. Investor Relations Report.
- Mullainathan, S. and Spiess, J. (2017). Machine learning: An applied econometric approach. *Journal of Economic Perspectives*, 31(2):87–106.
- Papke, L. E. and Wooldridge, J. M. (1996). Econometric methods for fractional response variables with an application to 401(k) plan participation rates. *Journal of Applied Econometrics*, 11(6):619–632. PDF gratuito: https://www.nber.org/system/files/working_papers/t0147/t0147.pdf.
- Ready Set (2025). Creative diversity score. Ready Set Agency. Framework interno, documentación disponible en <https://www.readyset.io/>.
- Salminen, J. O., Wahid, R. M., Yang, Y., and Jansen, B. J. (2024). Engagement patterns in TikTok: An analysis of short video ads. In *Proceedings of the ACM Conference on Hypertext & Social Media*.
- Schwartz, J. (2025). Alphabet/Google advertising revenue Q1 2025. Financial Report.
- Singular (2025). Ad fatigue: What it is and how to prevent it. Singular Blog. <https://singular.net/blog/>.
- Strobl, C., Boulesteix, A.-L., Kneib, T., Augustin, T., and Zeileis, A. (2008). Conditional variable importance for random forests. *BMC Bioinformatics*, 9:307. Open access: <https://pmc.ncbi.nlm.nih.gov/articles/PMC2491635/>.

- Strobl, C., Boulesteix, A.-L., Zeileis, A., and Hothorn, T. (2007). Bias in random forest variable importance measures: Illustrations, sources and a solution. *BMC Bioinformatics*, 8:25. Open access: <https://pmc.ncbi.nlm.nih.gov/articles/PMC1796903/>.
- Varian, H. R. (2014). Big data: New tricks for econometrics. *Journal of Economic Perspectives*, 28(2):3–28. PDF gratuito: <https://people.ischool.berkeley.edu/~hal/Papers/2013/ml.pdf>.
- White, H. (1980). A heteroskedasticity-consistent covariance matrix estimator and a direct test for heteroskedasticity. *Econometrica*, 48(4):817–838.
- Yang, J., Zhang, J., and Zhang, Y. (2025). Engagement That sells: Influencer video advertising on TikTok. *Marketing Science*, 44(2):247–267.
- Zhang, Z., Qiu, K., and Ye, Y. (2025). Influence of audiovisual features of short video advertising on consumer engagement behaviors: Evidence from TikTok. *Journal of Business Research*, 201:115662.

A. Anexos

A.1. Tabla de Acrónimos

Cuadro A.1: Tabla de acrónimos utilizados en el trabajo

Acrónimo	Definición
CDS	Creative Diversity Score
CTR	Click Through Rate
CPA	Cost Per Acquisition
OLS	Ordinary Least Squares (Mínimos Cuadrados Ordinarios)
RF	Random Forest
EDA	Exploratory Data Analysis
IA	Inteligencia Artificial
ITBA	Instituto Tecnológico de Buenos Aires

Fuente: Elaboración propia.

A.2. Resultados Regresión Lineal

La siguiente tabla presenta los coeficientes completos del modelo OLS estimado con errores estándar robustos HC1, incluyendo todas las categorías creativas y variables de control. En el cuerpo del trabajo (Tabla 4.1) se reportan únicamente las variables con $p < 0,05$ por claridad expositiva.

Cuadro A.2: Resultados completos del modelo OLS (variable dependiente: $\log(\text{CTR})$, errores estándar HC1)

Variable	Coef.	SE	<i>t</i>	<i>p</i>
<i>Creative Theme</i>				
Brand Story & Mission-Driven	-0.235	0.150	-1.57	0.117
Educational & Explainer	+0.105	0.106	+0.99	0.323
Humor & Entertainment	-0.470***	0.142	-3.32	0.001
Lifestyle & Aspirational	+0.028	0.102	+0.28	0.783
Not Applicable	-0.080	0.188	-0.42	0.672
Product-Centric	+0.240*	0.097	+2.48	0.013
Promotional & Offer-Based	+0.144	0.127	+1.13	0.258
Testimonial & Social Proof	+0.315**	0.108	+2.90	0.004
<i>Creative Concept</i>				
Animated explainer	-0.235	0.192	-1.22	0.221
Aspirational creator collaboration	+0.605***	0.142	+4.25	0.000
Before-and-after story	-0.188	0.148	-1.27	0.205
Behind-the-scenes	-0.170	0.117	-1.46	0.145
Cinematic brand film	+0.085	0.334	+0.25	0.799
Comparison	+0.226	0.372	+0.61	0.544
Day-in-the-life story	+0.404**	0.137	+2.95	0.003
Event-driven	+1.256**	0.428	+2.94	0.003
Expert review	-0.023	0.253	-0.09	0.927
FAQ	-0.387**	0.136	-2.84	0.004
Flash sale	-0.094	0.125	-0.75	0.450
Founder story	-0.041	0.131	-0.31	0.757
Limited-time offer	-0.022	0.122	-0.18	0.854
Member deal	-0.247	0.136	-1.82	0.069
Meme-based content	-0.561**	0.212	-2.64	0.008
Not Applicable	-0.079	0.087	-0.91	0.361
Parody	-0.310	0.269	-1.15	0.248
Product demo	-0.180	0.093	-1.93	0.054
Unboxing	-0.179	0.175	-1.02	0.307
<i>Talent Type</i>				
Actors	+0.164	0.102	+1.61	0.107
Combination of actors and customers	+0.152	0.118	+1.29	0.199
Combination of influencers and customers	-0.086	0.106	-0.80	0.421
Customers	-0.130*	0.061	-2.12	0.034
Experts	-0.020	0.093	-0.21	0.830
Influencers	+0.104	0.100	+1.05	0.296
No Talent	-0.134*	0.053	-2.52	0.012
<i>objective_value</i>				
App Installs	+0.147	0.094	+1.56	0.118
Conversions	-1.078***	0.060	-17.84	0.000